



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS
PRÓ-REITORIA DE ENSINO
CÂMPUS GOIÂNIA
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

WARLEY RODRIGUES DE ANDRADE

Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

Uma pipeline temporal para previsão de notas,
identificação de risco acadêmico e geração de
relatórios escolares

Goiânia, 2026.

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS

PRÓ-REITORIA DE ENSINO

CÂMPUS GOIÂNIA

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

WARLEY RODRIGUES DE ANDRADE

Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

**Uma pipeline temporal para previsão de notas,
identificação de risco acadêmico e geração de
relatórios escolares**

Trabalho de Conclusão de Curso apresentado à Coordenação do Curso de Bacharelado em Sistemas de Informação como requisito parcial para obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Otávio Xavier Calaça

Goiânia, 2026.

Obs: Após defesa e correção, imprimir da capa ao sumário e entregar na biblioteca ou encaminhar email, solicitando a elaboração da Ficha Catalográfica
email para orientação de elaboração da FICHA CATALOGRÁFICA
bib.goiania@ifg.edu.br (biblioteca do IFG)

Modelo:

A654	Aproveitamento da água pluvial como uma alternativa para substituição da água tratada nas instalações da SANEAGO : uma proposta de gerenciamento ambiental para o distrito norte / Elcio Vânio de Oliveira et al. – Goiânia, 2009. 00f. : il. Orientadora: Profª Drª Warde Antonieta da Fonseca-Zang Co-orientador; Profª. Dr. Joachim Werner Zang. Dissertação de Mestrado – Mestrado Profissional em Tecnologia de Processos Sustentáveis, Instituto Federal de Educação, Ciência e Tecnologia de Goiás. 1. Água pluvial – aproveitamento e alternativa 2. SANEAGO – tratamento de água – 4. Gerenciamento ambiental I. Fonseca-Zang, Warde Antonieta da (orientadora) II. Instituto Federal de Educação, Ciência e Tecnologia de Goiás, Mestrado em Tecnologia de Processos Sustentáveis. 1 CDD 363.700 817 3 2
-------------	---

Ficha catalográfica elaborada pelo responsável da Biblioteca Professor Jorge Félix de Souza,
Instituto Federal de Educação, Ciência e Tecnologia de Goiás

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS
PRÓ-REITORIA DE ENSINO
CÂMPUS GOIÂNIA
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

WARLEY RODRIGUES DE ANDRADE

Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

Uma pipeline temporal para previsão de notas,
identificação de risco acadêmico e geração de
relatórios escolares

Trabalho de Conclusão de Curso defendido no Curso de Bacharelado em Sistemas de Informação como requisito parcial para obtenção do título de Bacharel em Sistemas de Informação, aprovada em 21 de Abril de 2026, pela Banca Examinadora constituída pelos professores:

Prof. Dr. Otávio Xavier Calaça
IFG / Câmpus Goiânia
Orientador

Prof. Dr. Fulano de Tal
Instituição

Profa. Dra. Fulana de Tal
Instituição

Resumo

Título: Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

Autor: Warley Rodrigues de Andrade

Orientador: Prof. Dr. Otávio Xavier Calaça

Este Trabalho de Conclusão de Curso investiga como dados gerados pela rotina escolar podem ser organizados para apoiar intervenções pedagógicas antes que o aluno chegue a um quadro consolidado de baixo desempenho. O problema central consistiu em integrar notas, faltas, pagamentos e informações acadêmicas em uma pipeline capaz de prever a próxima nota do aluno em uma disciplina e sinalizar risco pedagógico de curto prazo. Ao longo do projeto, uma hipótese inicial baseada em grafos foi testada, mas os experimentos mostraram melhor aderência de uma abordagem temporal tabular, mais compatível com a natureza longitudinal dos registros escolares e com o tipo de decisão que a escola precisa tomar. A solução final foi implementada no pacote `school_predictor`, com separação entre a camada privada de preparação do banco e a camada pública reproduzível baseada em arquivos `CSV`. Sobre essa base, foram realizadas engenharia de atributos, validação temporal por ano letivo, comparação entre baselines, Random Forest e HistGradientBoosting, análise de erro e geração de relatórios operacionais. Nos experimentos, a previsão numérica da próxima nota obteve melhor resultado com histórico mínimo de uma observação anterior por disciplina, alcançando MAE de 0,7659. Já o alerta de risco apresentou melhor desempenho com histórico mínimo de duas observações, atingindo F1 de 0,7436 e recall de 0,8794 no teste temporal. Como resultado adicional, as saídas analíticas foram convertidas em relatórios destinados a professor, coordenação e secretaria, incluindo ranking executivo de prioridade. Conclui-se que uma arquitetura temporal voltada ao contexto escolar, quando combinada com interpretação, priorização e cuidado com dados sensíveis, pode ampliar a capacidade institucional de agir de forma mais precoce.

Palavras-chave

mineração de dados educacionais; previsão de desempenho escolar; aprendizado de máquina; risco pedagógico; learning analytics; modelagem temporal tabular.

Abstract

Title: Predictive system for school performance to support pedagogical decision-making

Author: Warley Rodrigues de Andrade

Advisor: Prof. Dr. Otávio Xavier Calaça

This undergraduate thesis presents the development of a predictive system for school environments. Its goal is to anticipate academic difficulties and support decision-making by teachers, pedagogical coordinators, and administrative staff. The research problem investigates whether historical school data, such as grades, absences, payments, and academic records, can be integrated into an analytical architecture capable of predicting a student's next grade and identifying pedagogical risk signals before failure or severe performance decline occurs. The project initially explored a graph-based approach, but evolved into a tabular temporal strategy after the analyses indicated stronger adherence between the problem and supervised models applied to longitudinal data. The final solution was organized around the `school_predictor` package, with a private local layer for database preparation and extraction, a public CSV-based interface, feature engineering, temporal validation, model selection, error analysis, and report generation. Baselines, Random Forest, and HistGradientBoosting were compared for both next-grade regression and classification of risk for grades below 6.0. For numeric next-grade prediction, the best setting used a minimum history of one prior observation per subject and achieved MAE of 0.7659. For risk alerting, the best setting used a minimum history of two prior observations, achieving F1 of 0.7436 and recall of 0.8794 in temporal testing. In addition to predictive modeling, a school reporting layer was developed with outputs for teachers, coordination, and school administration, including an executive ranking of priority students. The study concludes that a temporal analytical architecture oriented toward institutional use, combined with interpretation, prioritization, and data protection mechanisms, can support earlier pedagogical intervention.

Keywords

educational data mining; student performance prediction; machine learning;
pedagogical risk; learning analytics; tabular temporal modeling.

Sumário

1	Introdução	9
1.1	Objetivos.....	10
1.2	Justificativa	10
1.3	Delimitação do tema	11
1.4	Estrutura do trabalho.....	11
2	Fundamentação Teórica e Trabalhos Relacionados	12
2.1	Mineração de Dados Educacionais e Learning Analytics.....	12
2.2	Previsão de desempenho escolar	12
2.3	Modelos de aprendizado de máquina no projeto	13
2.3.1	Random Forest.....	13
2.3.2	LSTM	13
2.3.3	Gradient Boosting.....	14
2.3.4	Classificação supervisionada e regras simples.....	14
2.4	Dados temporais, validade e métricas.....	14
2.5	Ética, privacidade e interpretabilidade.....	15
2.6	Trabalhos relacionados	15
2.6.1	Comparação com estudos de previsão de nota e detecção de risco	16
3	Materiais, Métodos e Evolução do Projeto	19
3.1	Natureza da pesquisa	19
3.2	Fonte de dados e preparo inicial	19
3.3	Estratégia metodológica	20
3.4	Evolução histórica do projeto	20
3.4.1	Fase inicial orientada a grafo.....	20
3.4.2	Fase exploratória com testes clássicos e PCA	21
3.4.3	Fase temporal com LSTM	21
3.4.4	Fase tabular com Random Forest	21
3.4.5	Refatoração para pipeline real	21
3.5	CrITÉrios de avaliação	22
4	Arquitetura da Solução e Integração dos Dados	23
4.1	Visão geral da arquitetura	23
4.2	Modos de execução.....	24
4.3	Configuração experimental e reprodutibilidade	25
4.3.1	Camadas de entrada.....	26
4.3.2	Arquivos de entrada canônicos	27
4.3.3	Execução reprodutível da pipeline.....	27

4.3.4	Modos e artefatos analíticos	28
4.3.5	Artefatos operacionais finais	29
4.3.6	Condição mínima de reprodutibilidade	29
4.4	Integração de notas, faltas, pagamentos e professores.....	29
4.5	Engenharia de atributos	30
4.6	Construção do alvo e prevenção de vazamento.....	31
4.7	Camada de relatórios	31
4.8	Estrutura final do repositório e do fluxo operacional	32
5	Modelagem, Relatórios e Resultados	33
5.1	Modelos candidatos e critérios de seleção	33
5.2	Comparação dos candidatos na validação	33
5.3	Resultados do modo de previsão de nota	35
5.4	Resultados do modo de alerta de risco	35
5.5	Comparando históricos mínimos	36
5.6	Exemplo interpretado de alerta	37
5.7	Geração de relatórios escolares.....	38
5.8	Análise de erro e calibração	38
6	Discussão, Limitações e Conclusão	40
6.1	Discussão dos resultados	40
6.2	Limitações do trabalho.....	40
6.3	Conclusão	41
6.4	Trabalhos futuros	42
	Referências	43
	Apêndice A – Estrutura resumida da solução	45
A.1	Organização do repositório.....	45
A.2	Módulos centrais da pipeline.....	45
A.3	Artefatos principais gerados	46

Introdução

O contexto escolar produz diariamente um volume expressivo de dados acadêmicos, administrativos e operacionais. Notas, faltas, registros financeiros, turmas, séries e históricos disciplinares são continuamente armazenados pelos sistemas institucionais, mas nem sempre se convertem em informação útil para a tomada de decisão pedagógica. Na prática, a escola registra muito, mas ainda explora pouco esse conjunto de dados para antecipar dificuldades de aprendizagem e organizar intervenções mais precoces. Este trabalho parte dessa lacuna.

Na rotina escolar, boa parte das intervenções ainda acontece de forma reativa. Em geral, professores, coordenação e secretaria percebem o problema quando o aluno já apresenta queda acentuada de desempenho, ausências recorrentes ou risco concreto de reprovação. Nesse momento, a margem de ação é menor e o custo institucional tende a ser maior. Diante disso, este Trabalho de Conclusão de Curso (TCC) investiga se os dados históricos já disponíveis na escola podem ser utilizados para antecipar sinais de risco acadêmico com antecedência suficiente para apoiar intervenções reais.

O problema central deste trabalho pode ser sintetizado da seguinte forma: como integrar dados escolares históricos de notas, faltas, pagamentos e registros acadêmicos em uma pipeline preditiva capaz de antecipar a próxima nota do aluno e sinalizar risco pedagógico, produzindo relatórios úteis para a tomada de decisão institucional? A partir dessa formulação, o trabalho foi conduzido pela hipótese de que uma arquitetura analítica temporal, sustentada por dados tabulares e validação cronológica, seria mais aderente ao problema real do que abordagens puramente relacionais ou experimentos isolados. Essa hipótese não foi apenas assumida de início: ela foi sendo confirmada ao longo da evolução do projeto, especialmente quando a solução deixou de priorizar grafos e passou a concentrar esforços em modelagem supervisionada sobre dados longitudinais.

1.1 Objetivos

O objetivo geral do trabalho é desenvolver uma pipeline preditiva baseada em dados escolares reais para prever a próxima nota do aluno, identificar risco pedagógico e gerar relatórios operacionais de apoio à decisão para professores, coordenação e secretaria.

Como objetivos específicos, o trabalho busca:

1. investigar a viabilidade de diferentes abordagens computacionais para o domínio escolar;
2. estruturar um fluxo de manutenção, anonimização e extração da base institucional;
3. integrar dados de notas, faltas, pagamentos e contexto acadêmico em uma base longitudinal;
4. construir atributos temporais capazes de representar a trajetória recente do aluno;
5. comparar modelos e baselines com validação temporal;
6. transformar as saídas técnicas em relatórios compreensíveis para a escola.

1.2 Justificativa

O trabalho se justifica em três planos complementares. No plano acadêmico, dialoga com as áreas de Educational Data Mining (EDM) e Learning Analytics (LA), mostrando como um problema institucional real pode ser tratado por meio de integração de dados, modelagem e geração de artefatos operacionais (Romero; Ventura, 2010; Baker; Inventado, 2014; Siemens; Baker, 2012). No plano tecnológico, a contribuição está em sair de experimentos pontuais e consolidar uma pipeline reproduzível, com separação entre preparação local dos dados, modelagem e saídas de uso institucional. No plano social e educacional, a relevância está na possibilidade de apoiar intervenções mais precoces, antes que o aluno atinja um quadro de maior gravidade.

Também existe justificativa ética. Em educação, sistemas preditivos não devem substituir o julgamento pedagógico humano, mas sim apoiar a priorização e a leitura do contexto. Por isso, o sistema proposto foi concebido como ferramenta de apoio à decisão e não como mecanismo automático de julgamento. Em outras palavras, o objetivo não é rotular o aluno de forma definitiva, mas oferecer sinais adicionais para que a escola consiga agir antes.

1.3 Delimitação do tema

Este trabalho não trata de evasão escolar em sentido amplo, nem pretende substituir os processos formais de avaliação da escola. O foco está na previsão da próxima nota e na identificação de risco pedagógico de curto prazo, com base em registros institucionais já existentes. A pesquisa também se limita aos dados disponíveis no banco escolar analisado e às rotinas que puderam ser tratadas, anonimizadas e extraídas para a pipeline. Isso significa que as conclusões do trabalho devem ser lidas dentro desse contexto específico de dados, regras e disponibilidade institucional.

1.4 Estrutura do trabalho

Esta monografia foi organizada em seis capítulos. O Capítulo 1 apresenta o problema, os objetivos e a justificativa. O Capítulo 2 discute a fundamentação teórica e os trabalhos relacionados. O Capítulo 3 descreve a natureza da pesquisa e a evolução histórica do projeto. O Capítulo 4 detalha a arquitetura proposta, a integração dos dados e a construção do dataset. O Capítulo 5 apresenta a modelagem, os relatórios e os resultados experimentais. Por fim, o Capítulo 6 discute limitações, conclusões e trabalhos futuros.

Fundamentação Teórica e Trabalhos Relacionados

2.1 Mineração de Dados Educacionais e Learning Analytics

A Mineração de Dados Educacionais (EDM) dedica-se ao desenvolvimento de métodos para explorar dados oriundos de contextos educacionais com o objetivo de compreender, monitorar e melhorar processos de aprendizagem (Romero; Ventura, 2010; Romero *et al.*, 2010). De forma complementar, Learning Analytics (LA) enfatiza a medição, coleta, análise e relato de dados sobre aprendizes e seus contextos para apoiar decisões pedagógicas e institucionais (Siemens; Baker, 2012; Baker; Inventado, 2014).

Neste trabalho, essas duas perspectivas aparecem de forma integrada. Do lado de EDM, o projeto constrói atributos, testa modelos supervisionados e compara métricas. Do lado de LA, o foco está em transformar resultados analíticos em saídas compreensíveis para a rotina escolar. Essa combinação é importante porque o problema estudado não termina na previsão em si: ele só faz sentido quando a saída pode ser lida e usada por quem toma decisões na escola.

2.2 Previsão de desempenho escolar

Prever desempenho escolar pode assumir diferentes formas: prever evasão, reprovação, engajamento, necessidade de reforço ou nota futura. Este trabalho escolhe como foco principal a previsão da próxima nota, porque esse alvo preserva maior granularidade pedagógica e permite intervenções mais precoces. Em paralelo, o projeto treina um classificador próprio para estimar o risco de a próxima nota ficar abaixo de 6,0, aproximando a modelagem do uso institucional sem reduzir o alerta a uma regra simples aplicada sobre a nota prevista.

2.3 Modelos de aprendizado de máquina no projeto

O projeto avaliou modelos supervisionados adequados a dados tabulares, com histórico irregular entre alunos, disciplinas e anos letivos. A escolha dos candidatos levou em conta quatro critérios práticos: capacidade de capturar relações não lineares, robustez diante de atributos heterogêneos, custo razoável de treinamento e possibilidade de comparar o desempenho com regras simples de referência. Assim, a discussão sobre modelos neste capítulo não tem apenas caráter conceitual: ela ajuda a explicar por que certos caminhos foram testados, descartados ou mantidos na versão final do projeto.

Algoritmos como regressão linear e árvore de decisão simples seriam mais fáceis de explicar, mas tenderiam a representar de forma limitada interações entre nota anterior, tendência, faltas, pagamentos e contexto escolar. Métodos como Support Vector Machine (SVM) poderiam ser usados, mas costumam exigir maior cuidado com escala, ajuste de hiperparâmetros e interpretação em bases tabulares maiores. Redes neurais profundas, por sua vez, foram consideradas menos aderentes ao volume e à irregularidade das sequências disponíveis. Modelos como CatBoost e LightGBM permanecem como alternativas futuras, mas não foram priorizados na versão final para manter a solução mais simples, reproduzível e apoiada em bibliotecas já consolidadas no ambiente do projeto. Em outras palavras, a seleção dos candidatos buscou equilibrar desempenho, legibilidade e viabilidade real de manutenção.

2.3.1 Random Forest

O *Random Forest*, proposto por Breiman (Breiman, 2001), foi importante no projeto por servir como primeiro modelo tabular forte após a fase exploratória. Sua principal vantagem está na robustez em dados tabulares, na capacidade de capturar relações não lineares e na boa tolerância a atributos heterogêneos. No desenvolvimento deste trabalho, ele teve um papel de referência concreta: ajudou a estabelecer um patamar forte de comparação antes da consolidação de outros candidatos.

2.3.2 LSTM

As redes Long Short-Term Memory (LSTM), introduzidas por Hochreiter e Schmidhuber (Hochreiter; Schmidhuber, 1997), foram consideradas por causa da natureza temporal do problema. No entanto, a base real revelou sequências

irregulares, entradas e saídas de alunos e históricos de extensão muito desigual. Esses fatores reduziram a aderência dessa abordagem ao escopo institucional do trabalho. O ponto aqui não é afirmar que LSTM seja inadequada em termos absolutos, mas reconhecer que, neste conjunto de dados e neste problema, ela não parecia ser a escolha mais consistente.

2.3.3 Gradient Boosting

O *Gradient Boosting*, formalizado por Friedman (Friedman, 2001), mostrou-se especialmente adequado à solução final por trabalhar bem com dados tabulares e atributos derivados. A variação *HistGradientBoosting* foi incluída por ser eficiente em bases tabulares e por lidar bem com padrões não lineares. Na rodada final, ele foi o melhor candidato para o modo de alerta de risco, enquanto o *Random Forest* permaneceu competitivo e foi selecionado para a regressão no modo de previsão de nota. Esse resultado reforça que o projeto não convergiu para um único modelo universal, mas para escolhas diferentes conforme a natureza de cada tarefa.

2.3.4 Classificação supervisionada e regras simples

Uma decisão importante foi manter a classificação de risco como tarefa supervisionada, em vez de utilizar apenas regras fixas, como “se a nota prevista for menor que 6, então o aluno está em risco”. Essa regra seria simples, mas perderia parte do comportamento temporal do problema. O aluno pode ter uma nota prevista numericamente próxima da média e, ainda assim, apresentar padrão de queda, histórico anterior fraco na disciplina, faltas acumuladas ou distância negativa em relação à turma. A classificação aprende diretamente com exemplos históricos quais combinações desses sinais antecederam notas futuras abaixo de 6,0. Essa escolha ajuda a aproximar o alerta da dinâmica real do acompanhamento escolar.

Isso não elimina as regras. No projeto, regras e pontuações continuam sendo usadas na camada de relatórios e priorização. A diferença é que o alerta principal de risco é estimado por um classificador treinado com dados reais, enquanto as regras ajudam a organizar a comunicação pedagógica e a calibrar prioridades.

2.4 Dados temporais, validade e métricas

Um ponto crítico em aplicações educacionais é a validação temporal. Em vez de dividir aleatoriamente treino e teste, este trabalho adota separação por anos letivos, evitando vazamento entre passado e futuro. Essa decisão aproxima a avaliação do uso real da solução, em que a escola precisa prever o próximo período

a partir do passado já conhecido. A preocupação com validação temporal também é discutida em estudos sobre avaliação de modelos em dados dependentes do tempo, nos quais uma divisão aleatória pode produzir estimativas otimistas de desempenho (Bergmeir; Hyndman; Koo, 2018). Para este TCC, esse cuidado é central porque o objetivo não era apenas obter uma métrica melhor, mas testar uma situação mais parecida com o uso futuro da pipeline.

As métricas escolhidas acompanham essa dupla natureza do problema. Para regressão, o trabalho utiliza Mean Absolute Error (MAE), que mede o erro médio absoluto em pontos de nota, e Root Mean Squared Error (RMSE), que penaliza erros maiores com mais intensidade. Para classificação de risco, utiliza *precision*, *recall* e F1-score (F1). A *precision* indica, entre os alunos sinalizados, quantos realmente estavam em risco; o *recall* indica, entre os alunos que realmente estavam em risco, quantos foram recuperados pelo modelo; e o F1 combina essas duas medidas. Essa combinação permite avaliar tanto proximidade numérica quanto capacidade de recuperar casos críticos.

2.5 Ética, privacidade e interpretabilidade

O uso de dados educacionais exige atenção especial à privacidade, à finalidade do tratamento e à interpretação cuidadosa das saídas. Discussões em LA e EDM mostram que proteção de dados e governança não são barreiras para análise, mas condições para seu uso institucionalmente legítimo (Slade; Prinsloo, 2013; Gasevic; Dawson; Jovanovic, 2016; Khalil; Ebner, 2016). No contexto brasileiro, a Lei Geral de Proteção de Dados Pessoais (LGPD) reforça esse cuidado (Brasil, 2018). No caso deste projeto, essa discussão não aparece apenas como requisito formal: ela interfere diretamente na forma de extrair, preparar, armazenar e comunicar os resultados.

Por isso, o projeto incorporou anonimização da base e assumiu, desde o início, que a saída do sistema não poderia ser um veredito definitivo sobre o aluno. Os relatórios foram desenhados para indicar fatores de alerta e recomendações iniciais, preservando o papel humano na decisão pedagógica (Fiok *et al.*, 2022).

2.6 Trabalhos relacionados

Os trabalhos relacionados ao tema podem ser agrupados em três eixos. O primeiro reúne revisões gerais da área, como as de Romero e Ventura (Romero; Ventura, 2010) e de Baker e Inventado (Baker; Inventado, 2014). O segundo eixo envolve estudos preditivos aplicados à educação, sobretudo aqueles que combinam múlti-

plas fontes de informação. O terceiro eixo aborda interpretabilidade, governança e questões éticas. Entre esses conjuntos, os trabalhos mais diretamente ligados a esta monografia são os que tratam de previsão de nota e detecção de risco acadêmico.

2.6.1 Comparação com estudos de previsão de nota e detecção de risco

Considerando o foco deste trabalho em prever a próxima nota e sinalizar risco pedagógico, a literatura mais próxima pode ser organizada em dois subconjuntos: estudos voltados à previsão de nota futura e estudos voltados à detecção de alunos em risco acadêmico. A Tabela 1 resume dois estudos representativos do primeiro grupo, de Morsy e Karypis (Morsy; Karypis, 2017) e de Widjaja et al. (Widjaja et al., 2020). Eles ajudam a situar o problema da regressão da próxima nota dentro de uma linha de pesquisa já consolidada, embora majoritariamente concentrada em ensino superior.

Tabela 1 – *Trabalhos correlatos focados em previsão de nota futura.*

Trabalho	Entradas	Saída e métodos	Limite frente a este TCC
Morsy e Karypis (2017)	Histórico aluno-disciplina e relações de conhecimento entre cursos em base universitária	Regressão da nota em disciplinas do próximo período por meio de <i>Cumulative Knowledge-based Regression Models</i>	Foco em matrícula universitária futura; não trata alerta pedagógico por etapa nem relatórios operacionais escolares
Widjaja et al. (2020)	Histórico aluno-curso, atributos de aluno e atributos de curso em contexto universitário	Predição de nota do próximo termo com <i>Factorization Machine</i> e <i>LSTM-FM</i>	Foco em desempenho por termo e escolha de cursos; não integra risco pedagógico separado nem sinais administrativos escolares

Fonte: Elaborada pelo autor com base nos trabalhos citados.

Esses estudos mostram que a previsão de nota futura já está consolidada como problema relevante, sobretudo em ensino superior. Entretanto, o alvo adotado costuma ser a nota em disciplinas ainda não cursadas ou em um próximo termo acadêmico. Aqui, a saída de regressão foi reposicionada para a próxima nota observada dentro da sequência temporal da mesma disciplina, o que favorece intervenções pedagógicas de curto prazo no cotidiano escolar. Essa mudança de foco é pequena em aparência, mas importante em termos de uso prático.

A Tabela 2 resume dois trabalhos representativos do eixo de detecção de risco, de Lakkaraju et al. (Lakkaraju et al., 2015) e de Koprinska, Stretton e Yacef (Koprinska; Stretton; Yacef, 2015). Nesse grupo, a proximidade com esta pesquisa

aparece menos no tipo exato de alvo e mais na preocupação com identificação precoce e utilidade institucional.

Tabela 2 – *Trabalhos correlatos focados em detecção de risco acadêmico.*

Trabalho	Entradas	Saída e métodos	Limite frente a este TCC
Lakkaraju et al. (2015)	Histórico escolar, notas, ausências, indicadores demográficos e administrativos em dois distritos dos EUA	Classificação binária de risco de não concluir o ensino médio no tempo esperado, com comparação entre classificadores e visualização para gestores	O alvo é conclusão escolar de longo prazo; não prevê a próxima nota da disciplina nem trabalha com saída combinada de regressão e risco
Koprinska, Stretton e Yacef (2015)	Notas parciais, submissões em sistema de correção automática e atividade em fórum de discussão em disciplina de programação	Classificação de aprovação ou falha no exame final com árvore de decisão e regras acionáveis para remediação	Estudo concentrado em uma disciplina universitária e em dados de ambiente digital; não integra contexto financeiro, professor, série ou relatórios multiautores

Fonte: Elaborada pelo autor com base nos trabalhos citados.

Nos estudos de risco, nota-se forte preocupação com identificação precoce, interpretabilidade e apoio à intervenção. Esse ponto aproxima-se diretamente deste TCC. A diferença principal está no fato de que o problema aqui não trata risco apenas como evasão, conclusão tardia ou aprovação final em uma disciplina. O alvo binário foi definido como o risco de a próxima nota observada ficar abaixo de 6,0, o que torna o alerta mais próximo da linguagem pedagógica da escola e mais aderente a decisões de curto prazo.

Do ponto de vista metodológico, o trabalho combina ideias que na literatura frequentemente aparecem separadas. Dos estudos de previsão de nota, aproveita a lógica de usar o histórico acadêmico como base para regressão temporal. Dos estudos de risco, incorpora a necessidade de triagem antecipada, priorização de casos e utilidade institucional. A diferença é que essas duas perspectivas foram unificadas em uma mesma arquitetura temporal com duas saídas supervisionadas: `target_nota_proxima` e `target_risco_proxima`.

Também há diferenças importantes nas entradas e nas ferramentas analíticas. Enquanto os trabalhos universitários de previsão de nota concentram-se sobretudo em relações aluno-curso e atributos acadêmicos, e os trabalhos de risco costumam enfatizar desempenho, engajamento ou indicadores administrativos amplos, este TCC articula notas, faltas, pagamentos, professor e contexto escolar em uma mesma base temporal. Em termos de modelagem, utiliza *Random Forest*, *HistGradientBoosting* e baselines heurísticos como referência honesta de comparação, todos avaliados por validação temporal por ano letivo. Em termos de saída, a solução não

termina na métrica: as predições alimentam relatórios para professor, coordenação e secretaria, além de ranking executivo de prioridade.

Em relação a esses trabalhos, este TCC se diferencia por articular toda a trajetória de um projeto aplicado: tratamento do banco, refatoração arquitetural, validação temporal, geração de relatórios e ranking executivo. Em vez de comparar apenas algoritmos em um *dataset* pronto, o trabalho documenta a construção completa de uma solução voltada ao contexto escolar, reunindo previsão da próxima nota, alerta de risco pedagógico e operacionalização institucional em uma mesma pipeline reproduzível. Esse posicionamento ajuda a explicar a contribuição do trabalho não apenas como experimento de modelagem, mas como solução analítica aplicada.

Materiais, Métodos e Evolução do Projeto

3.1 Natureza da pesquisa

Esta pesquisa é aplicada, predominantemente quantitativa e com forte componente tecnológico-experimental. É aplicada porque busca responder a um problema concreto de acompanhamento escolar. É quantitativa porque trabalha com dados históricos estruturados, métricas preditivas e validação temporal. Também possui componente tecnológico porque não se limita à análise conceitual: envolve a construção efetiva de software, rotinas de extração, pipeline de modelagem e relatórios operacionais.

3.2 Fonte de dados e preparo inicial

Os dados utilizados são provenientes de uma base escolar real contendo registros de alunos, notas, faltas, pagamentos e informações acadêmicas e administrativas. A base institucional foi renovada com registros de 2026 e passou por um processo de manutenção para uso acadêmico. Esse fluxo incluiu renomeação da base, redução estrutural, reorganização de índices, atualização de estatísticas e anonimização dos registros sensíveis. Como a avaliação temporal depende de conhecer a próxima nota observada, os experimentos finais utilizaram 2025 como ano de teste consolidado; dados de 2026 permanecem relevantes para continuidade operacional, mas nem sempre possuem alvo futuro completo para avaliação experimental. Essa decisão ilustra um ponto importante do trabalho: nem todo dado disponível no banco pode ser usado da mesma forma em uma avaliação preditiva honesta.

Os arquivos principais extraídos para a pipeline foram:

- `aluno.csv`;
- `media_nota_aluno.csv`;

- `faltas_aluno.csv`;
- `pagamento_aluno.csv`;
- `responsaveis_aluno.csv`;
- `professor_disciplina.csv`, quando o vínculo docente estava disponível.

A descrição consolidada do contrato dessas entradas, da execução experimental e dos artefatos gerados pela pipeline é apresentada na Seção 4.3.

3.3 Estratégia metodológica

O trabalho foi conduzido de forma incremental. Em vez de partir diretamente para uma solução final, o projeto foi sendo refinado em ciclos de exploração, teste, diagnóstico de limitações e refatoração. Esse percurso não foi um desvio do objetivo do TCC; ao contrário, foi justamente o processo que permitiu identificar quais escolhas se sustentavam diante do problema real e quais pareciam boas apenas em um plano inicial mais abstrato.

Para organizar a apresentação desse percurso, também foi adotada uma leitura inspirada no ciclo Cross-Industry Standard Process for Data Mining (CRISP-DM) (Wirth; Hipp, 2000). Assim, o projeto pode ser compreendido em seis movimentos: entendimento do problema escolar, entendimento dos dados, preparação da base, modelagem, avaliação e disponibilização dos resultados em relatórios e painel. Essa estrutura foi usada como material demonstrativo nos notebooks do repositório, sem substituir a arquitetura de produção da aplicação. Em outras palavras, o CRISP-DM foi adotado aqui mais como lente de organização do percurso do que como descrição literal da implementação final.

3.4 Evolução histórica do projeto

3.4.1 Fase inicial orientada a grafo

O projeto começou com uma hipótese baseada em grafos heterogêneos, motivada pela natureza relacional do domínio escolar. Nessa etapa, foram produzidos módulos para leitura de entidades, construção de relações e consultas em estruturas relacionais. A ideia era representar alunos, matrículas, disciplinas, responsáveis, faltas e pagamentos como nós e arestas. Essa fase foi importante porque ajudou a explicitar a riqueza relacional do domínio, mesmo que depois ela não tenha permanecido como base da solução final.

3.4.2 Fase exploratória com testes clássicos e PCA

Na sequência, o projeto incorporou análises estatísticas e testes com classificadores tradicionais, além de redução exploratória de dimensionalidade com Principal Component Analysis (PCA). Essa fase foi importante para entender a distribuição dos atributos e perceber que o problema exigia mais do que uma base estática pivotada. Também foi nesse momento que ficou mais claro que o desempenho do aluno não poderia ser tratado de forma satisfatória sem considerar a ordem temporal das observações.

3.4.3 Fase temporal com LSTM

Como o problema possui natureza temporal, foi investigada também uma abordagem sequencial com Long Short-Term Memory (LSTM). Apesar de conceitualmente promissora, essa alternativa não se consolidou, sobretudo por depender de sequências mais homogêneas e longas do que as observadas na base. Na prática, a irregularidade dos históricos e a variedade de trajetórias entre alunos reduziram a aderência dessa solução ao escopo institucional do trabalho.

3.4.4 Fase tabular com Random Forest

Posteriormente, o projeto migrou para um desenho mais pragmático com *Random Forest*. Essa fase representou um avanço importante por aproximar a solução de um problema tabular supervisionado. Ainda assim, permaneceram limitações relacionadas ao pivotamento excessivo, perda de temporalidade e uso incompleto de dados como faltas e pagamentos. Foi uma etapa decisiva porque mostrou que o projeto estava mais próximo de uma formulação tabular temporal do que de uma representação fixa centrada apenas em atributos agregados.

3.4.5 Refatoração para pipeline real

O amadurecimento do trabalho levou primeiro à consolidação de uma pipeline intermediária de experimentação, e depois à arquitetura final entregue no pacote `school_predictor`. Essa arquitetura separou explicitamente:

- a camada de acesso e conexão com o banco;
- a preparação física e anonimização do banco restaurado;
- a extração dos dados para arquivos canônicos;
- a pipeline de modelagem e relatórios;
- a camada de visualização em dashboard.

Na versão final do repositório, a aplicação pública foi organizada em torno de `school_predictor/`, enquanto as consultas SQL reais e as rotinas detalhadas de operação com o banco passaram a ficar em uma camada local privada, fora do Git. Essa decisão tornou a solução mais adequada à publicação acadêmica, sem expor o desenho interno do banco institucional. Mais do que uma escolha de organização de código, isso foi parte do esforço para tornar o trabalho reproduzível sem comprometer dados ou estruturas sensíveis.

3.5 Critérios de avaliação

Os critérios de avaliação foram definidos em duas camadas. A primeira camada é estatística e envolve *MAE*, *RMSE*, *precision*, *recall* e *F1*. A segunda camada é institucional e pergunta se a solução consegue priorizar casos urgentes, gerar relatórios compreensíveis e apoiar diferentes atores escolares. Essa combinação foi necessária porque um modelo matematicamente competente nem sempre é automaticamente útil para a escola. Em um projeto como este, desempenho preditivo e utilidade operacional precisaram ser lidos em conjunto desde o início.

Arquitetura da Solução e Integração dos Dados

4.1 Visão geral da arquitetura

A arquitetura final foi organizada para separar claramente as responsabilidades do sistema. Essa organização não surgiu pronta desde o início; ela foi sendo consolidada à medida que o projeto deixou de ser apenas um conjunto de experimentos e passou a exigir uma estrutura reproduzível, compreensível e segura para publicação acadêmica. O fluxo consolidado pode ser resumido em oito etapas:


1. manutenção e anonimização da base original;
2. extração das tabelas relevantes para arquivos Comma-Separated Values (CSV);
3. leitura estruturada dessas fontes pela pipeline;
4. construção do dataset longitudinal;
5. separação temporal entre treino, validação e teste;
6. comparação automática entre modelos e baselines;
7. geração de previsões e análises de erro;
8. produção de relatórios operacionais para a escola.

Em termos de organização do código, o núcleo da solução ficou distribuído entre módulos de configuração, leitura das fontes, engenharia de atributos, modelagem, relatórios e orquestração.

Na versão final do repositório, essa organização foi consolidada no pacote `school_predictor/`, com artefatos locais centralizados em `artifacts/`. Essa separação tornou a arquitetura mais simples de compreender e mais segura para publicação do código. Em especial, ela ajudou a distinguir com clareza o que pertence à camada sensível de preparação dos dados e o que pode ser mostrado, executado e auditado no contexto do TCC.

A Figura 1 sintetiza essa organização por blocos estruturais: interfaces de entrada e uso, camada de aplicação, banco e extração, pipeline analítica, relatórios e consumo institucional. O objetivo aqui não é detalhar a sequência de execução, mas mostrar onde cada responsabilidade ficou concentrada na versão final do projeto.

Figura 1 – *Visão arquitetural da solução proposta.*



Fonte: Elaborada pelo autor.

4.2 Modos de execução

A pipeline foi dividida em dois modos complementares:

- `previsao_nota`: voltado à regressão da próxima nota, com histórico mínimo de uma observação anterior por disciplina;
- `alerta_risco`: voltado à classificação de risco de próxima nota abaixo de 6,0, com histórico mínimo de duas observações anteriores.

Essa divisão surgiu dos experimentos: o mesmo recorte de histórico não era o melhor para os dois objetivos. Assim, a arquitetura passou a preservar duas configurações operacionais, cada uma adequada ao seu uso principal. Em vez de forçar uma solução única para tarefas diferentes, o projeto assumiu explicitamente essa diferença como parte do desenho final.


Em ambos os modos, a função central de modelagem calcula sinais de regressão e de classificação. A diferença está no objetivo operacional, no histórico mínimo

exigido, no volume de dados resultante e no artefato usado como referência principal. No modo `previsao_nota`, a interpretação principal é o erro da nota prevista; no modo `alerta_risco`, a interpretação principal é a capacidade de recuperar alunos cuja próxima nota ficou abaixo da linha de segurança. Essa distinção ajuda a evitar uma leitura simplificada de que a pipeline executa exatamente a mesma coisa duas vezes.

4.3 Configuração experimental e reprodutibilidade

Para fins de reprodutibilidade, a configuração experimental final do projeto foi organizada como um contrato entre entradas canônicas, rotinas de execução e artefatos gerados. A ideia central foi permitir que a arquitetura pública do TCC pudesse ser compreendida, auditada e reexecutada sem expor o banco institucional nem as consultas SQL reais. Essa seção, portanto, não funciona apenas como inventário de arquivos: ela sintetiza a forma como a solução foi estabilizada para uso acadêmico.

A Figura 2 resume esse percurso operacional completo: mostra como os comandos principais partem da interface de linha de comando, acionam a preparação ou a extração quando necessário e, no fluxo principal, convergem para a construção do dataset temporal, para a execução dos modos `previsao_nota` e `alerta_risco` e para a consolidação final dos relatórios escolares.

Figura 2 – *Fluxo operacional principal da solução.*

Fonte: Elaborada pelo autor.

4.3.1 Camadas de entrada

A reprodução da solução foi separada em duas camadas complementares:

- **camada privada local:** prepara o banco restaurado, aplica anonimização e executa as consultas SQL reais fora do Git;
- **camada pública reproduzível:** consome arquivos CSV canônicos em `artifacts/database/csv/` e executa a pipeline acadêmica publicada no repositório.

Essa separação foi adotada para que a parte sensível da extração permanecesse protegida, enquanto a parte acadêmica e demonstrativa da solução continuasse passível de reprodução por terceiros. Na prática, ela permitiu conciliar duas exigências que normalmente entram em tensão em projetos escolares: proteger a estrutura institucional e, ao mesmo tempo, manter a rastreabilidade do experimento.

4.3.2 Arquivos de entrada canônicos

Os arquivos de entrada da arquitetura final foram definidos da seguinte forma:

- `aluno.csv`: identifica o aluno de forma pseudonimizada e preserva o contexto cadastral e escolar básico da extração;
- `media_nota_aluno.csv`: base principal de notas por aluno, disciplina, período e etapa; é o eixo central da modelagem;
- `faltas_aluno.csv`: registros de faltas usados para formar faltas por etapa e faltas acumuladas;
- `pagamento_aluno.csv`: registros financeiros resumidos para produzir sinais administrativos por aluno e ano letivo;
- `responsaveis_aluno.csv`: arquivo canônico complementar do projeto, preservado como parte do contrato público da extração;
- `professor_disciplina.csv`: contexto docente por disciplina e turma, incorporado quando esse vínculo está disponível.

Na pipeline central publicada, os arquivos consumidos diretamente pela modelagem e pelos relatórios são, principalmente, `media_nota_aluno.csv`, `faltas_aluno.csv`, `pagamento_aluno.csv` e `professor_disciplina.csv`. Os demais arquivos preservam o contrato público da extração e a rastreabilidade da arquitetura completa, mesmo quando não entram diretamente em todas as etapas da modelagem. Isso ajuda a explicar por que o contrato de entrada do projeto é um pouco mais amplo do que o conjunto estritamente consumido pelo treino final.

4.3.3 Execução reprodutível da pipeline

A execução experimental do projeto pode ser compreendida em dois cenários complementares.

No cenário completo, disponível apenas em ambiente local com acesso controlado ao banco restaurado, a rotina segue três movimentos:

1. preparar localmente o banco restaurado por meio da rotina `prepare-db`;
2. extrair os arquivos canônicos por meio da rotina `extract`;
3. executar a pipeline completa com a rotina `workflow`, responsável por acionar os dois modos principais e consolidar a camada final de relatórios.

No cenário público reproduzível, basta disponibilizar os CSVs canônicos em `artifacts/database/csv/`. A partir deles, a execução pode ocorrer por modo isolado ou de ponta a ponta:

- `pipeline -mode previsao_nota`: executa apenas o modo voltado à regressão da próxima nota;
- `pipeline -mode alerta_risco`: executa apenas o modo voltado à classificação de risco;
- `reports`: recompõe a camada final de relatórios a partir dos artefatos já produzidos;
- `workflow`: reconstitui o fluxo completo e produz a saída operacional final.

Essa organização foi importante porque o experimento final não depende de acesso direto ao banco para ser reproduzido academicamente; ele depende do contrato dos `CSVs` e de uma interface de execução padronizada. Em outras palavras, a reprodutibilidade do trabalho foi deslocada do banco institucional para a interface pública dos dados extraídos.

4.3.4 Modos e artefatos analíticos

Cada modo da pipeline grava seus resultados em um subdiretório de `artifacts/pipeline/`. Os dois diretórios centrais são `artifacts/pipeline/previsao_nota/` e `artifacts/pipeline/alerta_risco/`. Em ambos os casos, os principais artefatos gerados são:

- `student_prediction_dataset.csv`: base final preparada para a rodada de modelagem;
- `student_prediction_predictions.csv`: previsões e sinais de teste usados na avaliação;
- `student_prediction_report.txt`: resumo técnico com métricas e candidatos selecionados;
- `student_prediction_model.pkl`: modelo final persistido quando a solução vencedora depende de objeto supervisionado treinado;
- `error_analysis_by_subject.csv`: consolidação de erro por disciplina;
- `error_analysis_by_series.csv`: consolidação de erro por série;
- `error_analysis_by_score_band.csv`: consolidação de erro por faixa de nota;
- `error_analysis_summary.txt`: resumo textual das análises de erro.

Esses artefatos sustentam a leitura técnica do experimento, pois registram o tamanho da base resultante, os candidatos comparados, o desempenho temporal, as previsões no teste e os pontos de maior dificuldade do sistema. Eles também ajudam a separar a fase de modelagem da fase de consumo institucional dos resultados.

4.3.5 Artefatos operacionais finais

Após a execução dos dois modos, a camada final de disponibilização grava saídas em `artifacts/reports/`. Entre os arquivos mais relevantes estão:

- `relatorio_escolar_integrado.csv`: base consolidada que cruza previsão de nota, alerta de risco e sinais operacionais;
- `relatorio_professor.csv` e `relatorio_professor.txt`: visão por aluno e disciplina para apoio pedagógico direto;
- `relatorio_coordenacao.csv` e `relatorio_coordenacao.txt`: consolidados por série, disciplina e prioridade institucional;
- `relatorio_secretaria.csv` e `relatorio_secretaria.txt`: sinais administrativos e prioridades de contato;
- `relatorio_professores_por_turma.csv`: consolidação de risco por professor e turma;
- `relatorio_professores_geral.csv`: consolidação geral de risco por professor;
- `ranking_executivo_coordenacao` em formatos `.csv` e `.txt`: priorização executiva dos alunos mais urgentes para intervenção.

Esses relatórios representam a saída final do experimento no contexto do TCC, pois convertem resultados de modelagem em materiais de consulta orientados aos diferentes perfis institucionais da escola. Esse ponto é decisivo para o sentido do trabalho: a entrega não é apenas um modelo treinado, mas uma camada de saída pensada para uso real.

4.3.6 Condição mínima de reprodutibilidade

Assim, a condição mínima para reproduzir publicamente a configuração experimental não é o acesso ao banco institucional, mas sim a disponibilidade dos CSVs canônicos e a observância do fluxo operacional da aplicação. Essa decisão preserva a natureza sensível do ambiente escolar e, ao mesmo tempo, mantém a arquitetura suficientemente explícita para fins acadêmicos, de demonstração e de continuidade do projeto.

4.4 Integração de notas, faltas, pagamentos e professores

O trabalho foi estruturado para unir quatro blocos principais de informação:

- desempenho acadêmico;
- frequência;
- sinais administrativos e financeiros;
- contexto escolar, incluindo disciplina, série, turma e professor.

Do ponto de vista de engenharia, a entrada de dados foi organizada em duas camadas. A primeira camada é privada e local, responsável pela preparação do banco restaurado e pela execução das consultas SQL reais. A segunda camada é pública e reproduzível, baseada nos arquivos `CSV` canônicos consumidos pela pipeline em `artifacts/database/csv/`. Isso permite explicar e reproduzir a arquitetura sem divulgar a estrutura interna do banco institucional.

Conforme sintetizado na Seção 4.3, essa separação define o contrato de reprodução da solução. Nesta seção, o foco passa a ser a forma como esses blocos de dados foram integrados na modelagem. As notas representam o eixo central da modelagem. A partir delas, foram construídos históricos deslocados, médias móveis, tendências e estatísticas de referência. As faltas foram agregadas por etapa e acumuladas ao longo do tempo. Os pagamentos foram resumidos por ano letivo, incluindo quantidades, pendências e médias de atraso. O professor, quando disponível no banco atualizado, foi incorporado como atributo contextual, sem remover linhas quando o vínculo docente estivesse ausente. Esse desenho de integração foi importante porque evitou reduzir o problema a uma leitura puramente acadêmica da nota, mantendo sinais administrativos e contextuais que fazem parte da rotina escolar.

4.5 Engenharia de atributos

Os atributos criados para a modelagem incluem:

- nota anterior 1, 2 e 3;
- média das últimas notas;
- desvio histórico da disciplina;
- tendência da última nota;
- média histórica do aluno no ano;
- média do aluno no ano anterior;
- média da disciplina no ano anterior;
- média da corte por etapa;
- faltas da etapa;
- faltas acumuladas;
- movimentos financeiros registrados e pendentes no ano;

- dias até pagamento;
- indicador de disponibilidade do professor.

Os atributos diretamente derivados da trajetória de notas e faltas foram construídos por deslocamentos, acumulados ou agregações até a etapa observada, preservando a causalidade temporal do problema. Os sinais financeiros, por sua vez, foram usados como contexto administrativo agregado por aluno e ano letivo. Por isso, devem ser interpretados como variáveis institucionais de apoio, não como evidência causal isolada do desempenho. Essa distinção é importante para evitar leituras simplistas sobre o papel de cada grupo de atributos.

4.6 Construção do alvo e prevenção de vazamento

Foram definidos dois alvos principais:

1. `target_nota_proxima`, correspondente ao valor numérico da próxima nota observada;
2. `target_risco_proxima`, correspondente ao indicador binário de próxima nota inferior a 6,0.

Para evitar vazamento de informação, os atributos históricos de desempenho e frequência foram calculados por deslocamento, médias acumuladas ou agregações limitadas ao passado. Isso foi essencial para garantir que o desempenho medido refletisse um cenário real de uso, e não apenas um ajuste artificial a dados futuros. A prevenção de vazamento, neste caso, não foi um detalhe técnico menor, mas uma condição para que os resultados tivessem valor prático.

4.7 Camada de relatórios

Além da modelagem, a arquitetura incorpora uma camada própria de relatórios. Ela organiza saídas para os principais perfis escolares e consolidados complementares:

- relatório do professor, com foco por aluno e disciplina;
- relatório da coordenação, com agregados por série e disciplina;
- relatório da secretaria, com ênfase administrativa;
- ranking executivo de alunos prioritários;
- relatório escolar integrado, usado como base operacional unificada;
- consolidados de risco por professor, com e sem recorte por turma.

Essa camada foi decisiva para aproximar a solução do problema real da escola, convertendo resultados técnicos em informação acionável. O inventário operacional desses artefatos foi consolidado na Seção 4.3. Essa escolha também ajuda a marcar a diferença entre o que o modelo calcula e o que a escola efetivamente consome.

4.8 Estrutura final do repositório e do fluxo operacional

Na forma final do projeto, a base ativa do software ficou organizada nos seguintes blocos:

- `school_predictor/database`: acesso ao banco, wrappers públicos de preparação e extração, e contrato das consultas;
- `school_predictor/database/private_runtime.py`: camada local privada para preparação física do banco e extração com tratamento sensível;
- `school_predictor/database/private_sql/`: consultas SQL reais mantidas apenas no ambiente local;
- `school_predictor/pipeline`: construção do dataset, modelagem, avaliação e relatórios;
- `school_predictor/app`: dashboard em Streamlit;
- `artifacts/database/csv`: interface canônica de entrada da pipeline;
- `artifacts/pipeline` e `artifacts/reports`: saídas analíticas e operacionais.

Com isso, a arquitetura final passou a separar claramente o que precisa ficar privado por envolver estrutura institucional do banco e o que pode ser publicado para fins acadêmicos, reprodutibilidade e apresentação do TCC. Esse arranjo resume bem a direção adotada pelo projeto: preservar o contexto real da escola sem comprometer a possibilidade de explicar, auditar e continuar a solução.

Modelagem, Relatórios e Resultados

5.1 Modelos candidatos e critérios de seleção

A etapa de modelagem comparou candidatos de regressão, candidatos de classificação e baselines determinísticos. Essa organização foi importante porque o objetivo não era apenas treinar um algoritmo sofisticado, mas verificar se ele realmente acrescentava valor em relação a regras simples baseadas no próprio histórico de notas. Em um problema escolar, essa comparação é especialmente relevante: se uma heurística simples entrega resultado próximo ao de um modelo mais custoso, o ganho prático da solução precisa ser analisado com cuidado.

Os candidatos avaliados foram:

- *RandomForestRegressor* e *RandomForestClassifier*;
- *HistGradientBoostingRegressor* e *HistGradientBoostingClassifier*;
- baseline de última nota;
- baseline de média das duas últimas notas;
- baseline de média das três últimas notas;
- baseline híbrido.

Para regressão, o critério principal de seleção foi o Mean Absolute Error (MAE). Para classificação de risco, o critério principal foi o F1-score (F1), acompanhado de *precision* e *recall*. O MAE foi escolhido porque expressa o erro diretamente em pontos de nota, o que facilita a interpretação pedagógica. O F1 foi usado porque equilibra a capacidade de encontrar casos críticos com a precisão dos alertas emitidos.

5.2 Comparação dos candidatos na validação

A Tabela 3 mostra a comparação dos principais candidatos de regressão na etapa de validação. No modo de previsão de nota, o *Random Forest* foi ligeiramente

superior ao *HistGradientBoosting* em MAE, por isso foi selecionado como regressor principal desse modo. No modo de alerta de risco, por outro lado, o *HistGradientBoosting* foi o melhor regressor dentro do recorte com histórico mínimo maior. Mais do que apontar um vencedor absoluto, essa comparação indica que o comportamento dos candidatos muda conforme o recorte operacional da base.

Tabela 3 – *Comparação dos candidatos de regressão na validação.*

Modo e candidato	MAE	RMSE	Erro $\leq 0,5$	Fonte: Elaborada pelo autor com base nos artefatos da pipeline..
Previsão – Random Forest	0,8152	1,0907	0,4261	
Previsão – HistGradientBoosting	0,8191	1,0926	0,4156	
Previsão – baseline de última nota	0,9148	1,3015	0,4531	
Alerta – HistGradientBoosting	0,8124	1,1113	0,4429	
Alerta – Random Forest	0,8327	1,1167	0,4174	
Alerta – baseline de duas notas	0,9196	1,2746	0,4248	

A Tabela 4 apresenta a comparação dos candidatos de classificação para risco. O resultado mostra duas evidências importantes. Primeiro, baselines simples ainda são competitivos e precisam ser considerados. Segundo, no modo especificamente calibrado para alerta de risco, o *HistGradientBoostingClassifier* superou os demais candidatos em F1. Isso reforça que a classificação não pode ser tratada apenas como derivada automática da regressão; ela possui comportamento próprio e exige calibração específica.

Tabela 4 – *Comparação dos candidatos de classificação na validação.*

Modo e candidato	Precision	Recall	F1	Fonte: Elaborada pelo autor com base nos artefatos da pipeline..
Previsão – baseline de duas notas	0,7011	0,7744	0,7359	
Previsão – HistGradientBoosting	0,6172	0,8937	0,7302	
Previsão – Random Forest	0,5743	0,9158	0,7059	
Alerta – HistGradientBoosting	0,6980	0,8255	0,7564	
Alerta – baseline de duas notas	0,7165	0,7908	0,7518	
Alerta – Random Forest	0,6091	0,9036	0,7277	

5.3 Resultados do modo de previsão de nota

No modo `previsao_nota`, o melhor cenário foi obtido com histórico mínimo igual a 1. A base de modelagem alcançou 106.721 linhas, 1.378 alunos únicos, 53 disciplinas e 6 anos letivos considerados. O conjunto temporal foi organizado com treino em anos anteriores, validação em 2024 e teste em 2025. Esse recorte confirma um aspecto importante da arquitetura: para prever a próxima nota, vale a pena preservar mais observações, mesmo quando o histórico individual ainda é relativamente curto.

O melhor candidato de regressão foi o *RandomForestRegressor*, com os resultados finais apresentados na Tabela 5. Em termos práticos, isso significa que a previsão da próxima nota ficou, em média, a aproximadamente 0,77 ponto da nota realmente observada, superando a heurística simples de repetir a nota anterior. Embora esse erro não elimine incerteza pedagógica, ele já coloca a previsão em um patamar suficientemente informativo para apoiar triagem e acompanhamento.

Tabela 5 – *Resultados finais do modo de previsão de nota no teste temporal.*

Métrica	Valor	
MAE do modelo	0,7659	Fonte: Elaborada pelo autor com base nos
RMSE do modelo	1,0519	
Acerto com erro $\leq 0,5$	0,4649	
MAE do baseline de última nota	0,9138	
RMSE do baseline de última nota	1,2967	
		artefatos da pipeline..

5.4 Resultados do modo de alerta de risco

No modo `alerta_risco`, o melhor cenário foi obtido com histórico mínimo igual a 2. Nessa configuração, a base de modelagem alcançou 50.065 linhas, 1.179 alunos únicos e 53 disciplinas. O melhor classificador foi o *HistGradientBoostingClassifier*, com os resultados apresentados na Tabela 6. Em comparação com o modo de previsão de nota, a base fica menor, mas o sinal histórico torna-se mais consistente para uma tarefa de alerta.

O destaque está no *recall*. Em um sistema de alerta, perder casos realmente críticos tende a ser mais grave do que sinalizar alguns casos adicionais para

Tabela 6 – *Resultados finais do modo de alerta de risco no teste temporal.*

Métrica	Valor	
Precision do modelo	0,6442	
Recall do modelo	0,8794	Fonte: Elaborada pelo autor com base nos artefatos da pipeline..
F1 do modelo	0,7436	
F1 do baseline	0,7243	

acompanhamento. Por isso, esse resultado foi considerado adequado ao objetivo pedagógico do trabalho: priorizar alunos que merecem revisão humana, não produzir uma decisão automática. A leitura mais importante aqui não é apenas que o modelo “acerta”, mas que ele recupera boa parte dos casos que a escola provavelmente gostaria de revisar primeiro.

A Tabela 7 resume a matriz de confusão do modo de alerta de risco no teste temporal. Dos 2.794 casos que realmente tiveram próxima nota abaixo de 6,0, o modelo recuperou 2.457. Por outro lado, também sinalizou 1.357 casos que não se confirmaram como risco no alvo observado. Esse comportamento é coerente com uma ferramenta de triagem, pois privilegia cobertura dos casos críticos.

Tabela 7 – *Matriz de confusão do alerta de risco no teste temporal.*

Risco real	Predito sem risco	Predito com risco	
Sem risco	9.092	1.357	Fonte: Elaborada pelo autor com base nos artefatos da pipeline..
Com risco	337	2.457	

5.5 Comparando históricos mínimos

Os testes de histórico mínimo mostraram um resultado relevante para a arquitetura do projeto:

- `min_history = 1` foi melhor para regressão da próxima nota, pois preservou mais alunos e disciplinas na base;
- `min_history = 2` foi melhor para classificação de risco, pois exigiu maior evidência histórica antes de sinalizar alerta;

- `min_history = 3` reduziu demais a quantidade de casos e inviabilizou a validação temporal na rodada analisada.

Essa evidência levou à separação da pipeline em dois modos complementares de uso, cada um com sua configuração mais adequada. Trata-se de uma conclusão importante do TCC, porque mostra que a diferença entre prever nota e sinalizar risco não é apenas de métrica final, mas também de quantidade mínima de evidência histórica aceitável.

5.6 Exemplo interpretado de alerta

A Tabela 8 apresenta um caso pseudonimizado retirado dos artefatos de teste. O exemplo é útil porque mostra por que o projeto manteve um classificador de risco, e não apenas uma regra baseada na nota prevista.

Tabela 8 – *Exemplo pseudonimizado de caso sinalizado pelo alerta de risco.*

Campo	Valor observado
Aluno, série e disciplina	Aluno 01790, 1ª Série, Biologia 2
Etapla analisada	3º bimestre de 2025
Nota atual e próxima nota real	6,3 na etapa atual; 5,8 na etapa seguinte
Notas anteriores na disciplina	5,5 e 4,5
Média das duas últimas notas	5,0
Faltas acumuladas	7 faltas até a etapa analisada
Pagamentos pendentes no ano	0 pendências registradas
Média da corte na etapa	6,98
Professor vinculado	Professor 00019
Nota prevista pelo regressor	6,58
Alerta do classificador	Risco sinalizado corretamente

Fonte: Elaborada pelo autor com base nos artefatos da pipeline..

Se o sistema usasse apenas a regra “nota prevista menor que 6”, esse caso não seria sinalizado, pois a previsão numérica foi 6,58. O classificador, entretanto, identificou o risco a partir do conjunto de sinais: histórico anterior fraco na disciplina, média recente abaixo da linha de segurança, faltas acumuladas e desempenho abaixo da média da corte. Esse exemplo mostra que a regressão e a classificação são complementares. Ele também ajuda a explicar por que o trabalho optou por manter

duas saídas supervisionadas em vez de reduzir todo o problema a uma única previsão numérica.

5.7 Geração de relatórios escolares

Os resultados preditivos não foram o ponto final da solução. A partir deles, a camada final de relatórios passou a organizar saídas para três perfis institucionais:

- professor: com nota atual, nota prevista, fatores de alerta e recomendação pedagógica;
- coordenação: com visão por série, disciplina, ranking executivo e consolidados por professor;
- secretaria: com sinais administrativos relacionados a frequência, financeiro e prioridade de contato.

Também foram construídos consolidados por professor, com e sem recorte por turma, além do ranking executivo da coordenação. Essa camada aproxima a modelagem do cotidiano escolar, pois transforma predição, sinal de risco, pontuação e prioridade de intervenção em informação compreensível por cada perfil de uso. Em termos de contribuição do TCC, esse ponto é relevante porque desloca a discussão de “qual modelo venceu” para “como a saída se torna utilizável”.

5.8 Análise de erro e calibração

A análise de erro mostrou maior dificuldade de previsão em disciplinas como Matemática 3, Matemática 4 e 5, Biologia 2, História 2 e Química 3. Também houve maior erro nas faixas de nota abaixo de 7, especialmente porque esses casos são mais instáveis e pedagogicamente mais sensíveis. Essa leitura é importante porque os pontos de maior erro coincidem justamente com zonas em que a escola tende a demandar mais atenção.

Na camada operacional, a primeira regra de risco gerava excesso de casos classificados como alto risco. Por isso, foi criada uma pontuação composta que passou a combinar:

- predição de risco do modelo;
- nota prevista;
- nota atual;
- variação esperada;
- faltas acumuladas;

Tabela 9 – *Principais pontos de erro no modo de alerta de risco.*

Grupo analisado	Amostras	MAE	Acurácia de risco
Matemática 4 e 5	81	1,9489	0,7778
Biologia 2	260	1,5895	0,6500
História 2	81	1,3741	0,6667
Faixa abaixo de 6	2.794	1,0395	0,8794
Faixa de 6 a 6,99	1.405	0,9718	0,5103

Fonte: Elaborada pelo autor

com base nos artefatos da pipeline..

- pendências financeiras.

Com essa calibração, a priorização ficou mais compatível com o uso institucional, reduzindo sobrecarga sobre coordenação e professores. Assim, a saída final do sistema não deve ser lida como sentença sobre o aluno, mas como convite estruturado à investigação pedagógica. Esse fechamento sintetiza a posição adotada ao longo de todo o trabalho: a modelagem só faz sentido quando seus resultados podem ser interpretados, filtrados e usados com prudência.

Discussão, Limitações e Conclusão

6.1 Discussão dos resultados

Os resultados mostram que a solução final apresenta aderência melhor ao problema do que as hipóteses iniciais do projeto. Embora grafos e *LSTM* tenham sido importantes na fase exploratória, a experiência empírica indicou que o problema central estava melhor representado por uma base tabular temporal com atributos derivados e validação cronológica. Essa conclusão é relevante porque não foi assumida de antemão: ela surgiu do confronto entre diferentes caminhos metodológicos e os limites concretos da base escolar analisada.

Outro ponto importante é o valor dos baselines. Em diferentes momentos do trabalho, regras simples baseadas na última nota ou em médias móveis competiram de forma relevante com modelos mais sofisticados. Isso reforça que complexidade algorítmica não deve ser tomada como sinônimo automático de superioridade. No contexto deste TCC, esse cuidado ajudou a manter a análise mais honesta e mais próxima do uso real da solução.

Do ponto de vista institucional, o maior avanço do projeto não está apenas nas métricas, mas na passagem da predição para a ação. O valor do sistema aparece quando a nota prevista, o alerta de risco e os sinais complementares são convertidos em relatórios inteligíveis para professor, coordenação e secretaria. Na prática, esses alertas devem orientar investigação pedagógica, priorização de contato, planejamento de reforço e acompanhamento da evolução do aluno. Em outras palavras, a contribuição do trabalho se sustenta mais quando a modelagem é lida como apoio à decisão do que como mecanismo autônomo de julgamento.

6.2 Limitações do trabalho

As principais limitações identificadas foram:

1. o vínculo de professor ainda não cobre integralmente todo o histórico analisado;

2. o ranking executivo ainda concentra muitos casos nas faixas mais altas de prioridade;
3. a base de 2026 já existe, mas nem todos os cenários possuem alvo consolidado suficiente para teste completo;
4. o projeto utiliza variáveis institucionais disponíveis, mas não incorpora dimensões qualitativas, socioemocionais ou contextuais mais profundas;
5. a generalização para outras escolas exige adaptação local da arquitetura e nova validação.

Também existem ameaças à validade interna, externa e de construção. Nem toda queda de desempenho é explicada pelas variáveis disponíveis, e conceitos educacionais complexos acabam representados por *proxies* quantitativos, como faltas, pagamentos e trajetória de notas. Essa limitação não invalida o projeto, mas delimita com mais clareza o alcance de suas interpretações.

6.3 Conclusão

Este Trabalho de Conclusão de Curso apresentou o desenvolvimento de um sistema preditivo para apoio à decisão pedagógica com base em dados escolares reais. O projeto evoluiu de uma hipótese inicial orientada a grafos para uma pipeline temporal tabular reproduzível, capaz de:

- prever a próxima nota do aluno com desempenho superior a baselines simples;
- identificar risco de nota futura abaixo de 6 com *recall* elevado;
- integrar notas, faltas, pagamentos e contexto escolar em uma arquitetura única;
- transformar resultados técnicos em relatórios operacionais para diferentes atores da escola.

Em termos quantitativos, o modo de previsão numérica atingiu *MAE* de 0,7659, enquanto o modo de alerta de risco alcançou *F1* de 0,7436 e *recall* de 0,8794 no teste temporal. Em termos práticos, esses resultados indicam que a solução já pode servir como mecanismo de triagem e priorização institucional, desde que usada com supervisão humana e interpretação contextualizada. O ponto central não é afirmar que a escola passa a “saber o futuro” do aluno, mas que passa a dispor de um instrumento adicional para agir com mais antecedência.

Assim, a principal contribuição do trabalho não está apenas em acertar melhor uma nota futura, mas em mostrar que é possível construir uma arquitetura analítica coerente com o cotidiano da escola, eticamente defensável e operacionalmente útil. Nesse sentido, o TCC procura contribuir menos com uma promessa de

solução definitiva e mais com uma forma consistente de integrar dados, modelagem e uso institucional em educação.

6.4 Trabalhos futuros

Como continuidade natural do projeto, destacam-se os seguintes desdobramentos:

1. ampliar a cobertura do vínculo com professores;
2. recalibrar os limiares do ranking executivo;
3. incorporar técnicas adicionais de explicabilidade;
4. avaliar o impacto real dos relatórios na rotina escolar;
5. testar novos modelos tabulares, como CatBoost e LightGBM;
6. investigar variáveis qualitativas e socioemocionais;
7. validar a solução em outras escolas ou redes.

Referências

BAKER, Ryan S. J. d.; INVENTADO, Paulo S. Educational data mining and learning analytics. *In*: LARUSSON, Johann Ari; WHITE, Brandon (Ed.). **Learning Analytics: From Research to Practice**. New York: Springer, 2014. p. 61–75. 10, 12, 15

BERGMEIR, Christoph; HYNDMAN, Rob J.; KOO, Bonsoo. A note on the validity of cross-validation for evaluating autoregressive time series prediction. **Computational Statistics & Data Analysis**, v. 120, p. 70–83, 2018. 15

Brasil. **Lei nº 13.709, de 14 de agosto de 2018**. 2018. Lei Geral de Proteção de Dados Pessoais. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 21 abr. 2026. 15

BREIMAN, Leo. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. 13

FIOK, Krzysztof; KARWOWSKI, Waldemar; GUTIERREZ, Eduardo; WILAMOWSKI, Bogdan; REZA, Ali; AHRAM, Tareq. Explainable artificial intelligence for education and training. **Human Factors in Emerging Technologies and Society**, v. 19, n. 2, 2022. 15

FRIEDMAN, Jerome H. Greedy function approximation: A gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001. 14

GASEVIC, Dragan; DAWSON, Shane; JOVANOVIĆ, Jelena. Ethics and privacy as enablers of learning analytics. **Journal of Learning Analytics**, v. 3, n. 1, p. 1–4, 2016. 15

HOCHREITER, Sepp; SCHMIDHUBER, Jürgen. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. 13

KHALIL, Mohammad; EBNER, Martin. De-identification in learning analytics. **Journal of Learning Analytics**, v. 3, n. 1, p. 129–138, 2016. 15

KOPRINSKA, Irena; STRETTON, Joshua; YACEF, Kalina. Students at risk: Detection and remediation. *In: Proceedings of the 8th International Conference on Educational Data Mining*. International Educational Data Mining Society, 2015. p. 512–515. Disponível em: <https://www.educationaldatamining.org/EDM2015/proceedings/short512-515.pdf>. Acesso em: 1 jun. 2026. 16

LAKKARAJU, Himabindu; AGUIAR, Everaldo; SHAN, Carl; MILLER, David; BHANPURI, Nasir; GHANI, Rayid; ADDISON, Kecia L. A machine learning framework to identify students at risk of adverse academic outcomes. *In: Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: ACM, 2015. p. 1909–1918. 16

MORSY, Sara; KARYPIS, George. Cumulative knowledge-based regression models for next-term grade prediction. *In: Proceedings of the 2017 SIAM International Conference on Data Mining*. Philadelphia: SIAM, 2017. p. 552–560. 16

ROMERO, Cristóbal; VENTURA, Sebastián. Educational data mining: A review of the state of the art. **IEEE Transactions on Systems, Man, and Cybernetics, Part C**, v. 40, n. 6, p. 601–618, 2010. 10, 12, 15

ROMERO, Cristóbal; VENTURA, Sebastián; PECHENIZKIY, Mykola; BAKER, Ryan S. J. d. (Ed.). **Handbook of Educational Data Mining**. Boca Raton: CRC Press, 2010. 12

SIEMENS, George; BAKER, Ryan S. J. d. Learning analytics and educational data mining: Towards communication and collaboration. *In: Proceedings of the 2nd International Conference on Learning Analytics and Knowledge*. New York: ACM, 2012. p. 252–254. 10, 12

SLADE, Sharon; PRINSLOO, Paul. Learning analytics: Ethical issues and dilemmas. **American Behavioral Scientist**, v. 57, n. 10, p. 1510–1529, 2013. 15

WIDJAJA, Audrey Tedja; WANG, Lei; TRUONG, Nghia Trong; GUNAWAN, Aldy; LIM, Ee-Peng. Next-term grade prediction: A machine learning approach. *In: Proceedings of the 13th International Conference on Educational Data Mining*. International Educational Data Mining Society, 2020. p. 700–703. Disponível em: https://educationaldatamining.org/files/conferences/EDM2020/papers/paper_97.pdf. Acesso em: 1 jun. 2026. 16

WIRTH, Rüdiger; HIPPE, Jochen. **CRISP-DM: Towards a Standard Process Model for Data Mining**. Manchester: [s.n.], 2000. 20

Apêndice A – Estrutura resumida da solução

Este apêndice resume os principais blocos do repositório utilizados pela versão final do TCC.

A.1 Organização do repositório

- `school_predictor`: base ativa da aplicação final;
- `artifacts`: entrada e saída canônicas da pipeline no ambiente local;
- `docs`: documentação textual do projeto e apoio à defesa;
- `monografia`: projeto LaTeX da monografia e do pré-projeto;
- `diagrama`: diagramas da arquitetura e do fluxo de modelagem.

A.2 Módulos centrais da pipeline

`school_predictor/database/access.py` define a conexão com o banco por variáveis de ambiente;

`school_predictor/database/maintenance.py` expõe o wrapper público da preparação do banco;

`school_predictor/database/extraction.py` expõe o wrapper público da extração;

`school_predictor/database/private_runtime.py` concentra localmente as etapas privadas de preparação e extração;

`school_predictor/pipeline/dataset.py` constrói o dataset longitudinal e a engenharia de atributos;

`school_predictor/pipeline/modeling.py` realiza a validação temporal, seleção de candidatos e avaliação;

`school_predictor/pipeline/reporting.py` produz os relatórios para professor, coordenação e secretaria;

`school_predictor/cli.py` orquestra a operação principal do projeto.

A.3 Artefatos principais gerados

Entre os principais artefatos produzidos pela pipeline estão:

- arquivos CSV canônicos em `artifacts/database/csv`;
- artefatos analíticos por modo em `artifacts/pipeline/previsao_nota/` e `artifacts/pipeline/alerta_risco/`, incluindo dataset final, previsões, relatório técnico e análises de erro;
- relatórios operacionais em `artifacts/reports/`, com saídas para professor, coordenação e secretaria;
- relatório escolar integrado, consolidados por professor e ranking executivo da coordenação;
- painel em Streamlit para visualização operacional.

O detalhamento conceitual dessas entradas, saídas e artefatos está concentrado na Seção 4.3, enquanto este apêndice apenas resume a estrutura final da solução.