



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS
PRÓ-REITORIA DE ENSINO
CÂMPUS GOIÂNIA
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

WARLEY RODRIGUES DE ANDRADE

Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

Uma pipeline temporal para previsão de notas,
identificação de risco acadêmico e geração de
relatórios escolares

Goiânia, 2026.

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS

PRÓ-REITORIA DE ENSINO

CÂMPUS GOIÂNIA

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

WARLEY RODRIGUES DE ANDRADE

Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

**Uma pipeline temporal para previsão de notas,
identificação de risco acadêmico e geração de
relatórios escolares**

Trabalho de Conclusão de Curso apresentado à Coordenação do Curso de Bacharelado em Sistemas de Informação como requisito parcial para obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Otávio Calaça Xavier

Goiânia, 2026.

Resumo

Título: Sistema preditivo de desempenho escolar para apoio à decisão pedagógica

Autor: Warley Rodrigues de Andrade

Orientador: Prof. Dr. Otávio Calaça Xavier

Este Trabalho de Conclusão de Curso investiga como dados gerados pela rotina escolar podem ser organizados para apoiar intervenções pedagógicas antes que o aluno chegue a um quadro consolidado de baixo desempenho. O problema central consistiu em integrar notas, faltas, pagamentos e informações acadêmicas em uma pipeline capaz de prever a próxima nota do aluno em uma disciplina e sinalizar risco pedagógico de curto prazo. Ao longo do projeto, uma hipótese inicial baseada em grafos foi testada, mas os experimentos mostraram melhor aderência de uma abordagem temporal tabular, mais compatível com a natureza longitudinal dos registros escolares e com o tipo de decisão que a escola precisa tomar. A solução final foi implementada no pacote `school_predictor`, com separação entre a camada privada de preparação do banco e a camada pública reproduzível baseada em arquivos `CSV`. Sobre essa base, foram realizadas engenharia de atributos, validação temporal por ano letivo, comparação entre baselines, Random Forest e HistGradientBoosting, análise de erro e geração de relatórios operacionais. Nos experimentos, a previsão numérica da próxima nota obteve melhor resultado com histórico mínimo de uma observação anterior por disciplina, alcançando MAE de 0,7659. Já o alerta de risco apresentou melhor desempenho com histórico mínimo de duas observações, atingindo F1 de 0,7436 e recall de 0,8794 no teste temporal. Como resultado adicional, as saídas analíticas foram convertidas em relatórios destinados a professor, coordenação e secretaria, incluindo ranking executivo de prioridade. Conclui-se que uma arquitetura temporal voltada ao contexto escolar, quando combinada com interpretação, priorização e cuidado com dados sensíveis, pode ampliar a capacidade institucional de agir de forma mais precoce.

Palavras-chave

mineração de dados educacionais; previsão de desempenho escolar; aprendizado de máquina; risco pedagógico; learning analytics; modelagem temporal tabular.

Abstract

Title: Predictive system for school performance to support pedagogical decision-making

Author: Warley Rodrigues de Andrade

Advisor: Prof. Dr. Otávio Calaça Xavier

This undergraduate thesis presents the development of a predictive system for school environments. Its goal is to anticipate academic difficulties and support decision-making by teachers, pedagogical coordinators, and administrative staff. The research problem investigates whether historical school data, such as grades, absences, payments, and academic records, can be integrated into an analytical architecture capable of predicting a student's next grade and identifying pedagogical risk signals before failure or severe performance decline occurs. The project initially explored a graph-based approach, but evolved into a tabular temporal strategy after the analyses indicated stronger adherence between the problem and supervised models applied to longitudinal data. The final solution was organized around the `school_predictor` package, with a private local layer for database preparation and extraction, a public CSV-based interface, feature engineering, temporal validation, model selection, error analysis, and report generation. Baselines, Random Forest, and HistGradientBoosting were compared for both next-grade regression and classification of risk for grades below 6.0. For numeric next-grade prediction, the best setting used a minimum history of one prior observation per subject and achieved MAE of 0.7659. For risk alerting, the best setting used a minimum history of two prior observations, achieving F1 of 0.7436 and recall of 0.8794 in temporal testing. In addition to predictive modeling, a school reporting layer was developed with outputs for teachers, coordination, and school administration, including an executive ranking of priority students. The study concludes that a temporal analytical architecture oriented toward institutional use, combined with interpretation, prioritization, and data protection mechanisms, can support earlier pedagogical intervention.

Keywords

educational data mining; student performance prediction; machine learning;
pedagogical risk; learning analytics; tabular temporal modeling.

Sumário

1	Introdução	7
1.1	Objetivos.....	8
1.2	Justificativa	8
1.3	Delimitação do tema	9
1.4	Estrutura do trabalho.....	9
2	Fundamentação Teórica e Trabalhos Relacionados	10
2.1	Mineração de Dados Educacionais e Learning Analytics.....	10
2.2	Previsão de desempenho escolar	11
2.3	Modelos de aprendizado de máquina no projeto	11
2.3.1	Random Forest.....	12
2.3.2	LSTM	12
2.3.3	Gradient Boosting.....	12
2.3.4	Classificação supervisionada e regras simples.....	12
2.4	Dados temporais, validade e métricas.....	13
2.5	Ética, privacidade e interpretabilidade.....	13
2.6	Trabalhos relacionados	14
2.6.1	Comparação com estudos de previsão de nota e detecção de risco	14
3	Materiais, Métodos e Evolução do Projeto	18
3.1	Natureza da pesquisa	18
3.2	Fonte de dados e preparo inicial	18
3.3	Estratégia metodológica	19
3.4	Evolução histórica do projeto	19
3.4.1	Fase inicial orientada a grafo.....	19
3.4.2	Fase exploratória com testes clássicos e PCA	20
3.4.3	Fase temporal com LSTM	20
3.4.4	Fase tabular com Random Forest	20
3.4.5	Refatoração para pipeline real	20
3.5	CrITÉrios de avaliação	21
4	Arquitetura da Solução e Integração dos Dados	22
4.1	Visão geral da arquitetura	22
4.2	Modos de execução.....	23
4.3	Configuração experimental e reprodutibilidade	24
4.3.1	Camadas de entrada.....	24
4.3.2	Arquivos de entrada canônicos	25
4.3.3	Execução reproduzível da pipeline.....	25

4.3.4	Modos e artefatos analíticos	26
4.3.5	Artefatos operacionais finais	26
4.3.6	Condição mínima de reprodutibilidade	27
4.4	Integração de notas, faltas, pagamentos e professores.....	27
4.5	Engenharia de atributos	28
4.6	Construção do alvo e prevenção de vazamento.....	29
4.7	Camada de relatórios	29
4.8	Estrutura final do repositório e do fluxo operacional	29
4.9	Síntese técnica da replicação da solução	30
5	Modelagem, Relatórios e Resultados	33
5.1	Modelos candidatos e critérios de seleção	33
5.2	Comparação dos candidatos na validação.....	33
5.3	Estabilidade das rodadas experimentais	35
5.4	Resultados do modo de previsão de nota	35
5.5	Resultados do modo de alerta de risco.....	36
5.6	Comparando históricos mínimos	37
5.7	Exemplo interpretado de alerta	38
5.8	Geração de relatórios escolares.....	39
5.9	Análise de erro e calibração	39
6	Discussão, Limitações e Conclusão	41
6.1	Discussão dos resultados	41
6.2	Limitações do trabalho.....	42
6.3	Conclusão	42
6.4	Trabalhos futuros	43
	Referências	45
	Apêndice A – Estrutura resumida da solução	47
A.1	Organização do repositório.....	47
A.2	Módulos centrais da pipeline.....	47
A.3	Artefatos principais gerados	48

Introdução

O contexto escolar produz diariamente um volume expressivo de dados acadêmicos, administrativos e operacionais. Notas, faltas, registros financeiros, turmas, séries e históricos disciplinares são continuamente armazenados pelos sistemas institucionais, mas nem sempre se convertem em informação útil para a tomada de decisão pedagógica. Na prática, a escola registra muito, mas ainda explora pouco esse conjunto de dados para antecipar dificuldades de aprendizagem e organizar intervenções mais precoces. Este trabalho parte dessa lacuna.

Na rotina escolar, boa parte das intervenções ainda acontece de forma reativa. Em geral, professores, coordenação e secretaria percebem o problema quando o aluno já apresenta queda acentuada de desempenho, ausências recorrentes ou risco concreto de reprovação. Nesse momento, a margem de ação é menor e o custo institucional tende a ser maior. Diante disso, este Trabalho de Conclusão de Curso (TCC) investiga se os dados históricos já disponíveis na escola podem ser utilizados para antecipar sinais de risco pedagógico com antecedência suficiente para apoiar intervenções reais.

O problema central deste trabalho pode ser sintetizado da seguinte forma: como integrar dados escolares históricos de notas, faltas, pagamentos e registros acadêmicos em uma pipeline preditiva capaz de antecipar a próxima nota do aluno e sinalizar risco pedagógico, produzindo relatórios úteis para a tomada de decisão institucional? A partir dessa formulação, o trabalho foi conduzido pela hipótese de que uma arquitetura analítica temporal, sustentada por dados tabulares e validação cronológica, seria mais aderente ao problema real do que abordagens puramente relacionais ou experimentos isolados. Essa hipótese não foi apenas assumida de início: ela foi sendo confirmada ao longo da evolução do projeto, especialmente quando a solução deixou de priorizar grafos e passou a concentrar esforços em modelagem supervisionada sobre dados longitudinais.

1.1 Objetivos

O objetivo geral do trabalho é desenvolver uma pipeline preditiva demonstrada com dados escolares falsos gerados para prever a próxima nota do aluno, identificar risco pedagógico e gerar relatórios operacionais de apoio à decisão para professores, coordenação e secretaria.

Como objetivos específicos, o trabalho busca:

1. investigar a viabilidade de diferentes abordagens computacionais para o domínio escolar;
2. estruturar um fluxo de preparação local, geração de dados falsos e extração compatível com o contrato público;
3. integrar dados de notas, faltas, pagamentos e contexto acadêmico em uma base longitudinal;
4. construir atributos temporais que representem a trajetória recente do aluno;
5. comparar modelos e baselines com validação temporal;
6. transformar as saídas técnicas em relatórios compreensíveis para a escola.

1.2 Justificativa

O trabalho se justifica em três planos complementares. No plano acadêmico, dialoga com as áreas de Educational Data Mining (EDM) e Learning Analytics (LA), mostrando como um problema institucional real pode ser tratado por meio de integração de dados, modelagem e geração de artefatos operacionais. No plano tecnológico, a contribuição está em sair de experimentos pontuais e consolidar uma pipeline reproduzível, com separação entre preparação local dos dados, modelagem e saídas de uso institucional. No plano social e educacional, a relevância está na possibilidade de apoiar intervenções mais precoces, antes que o aluno atinja um quadro de maior gravidade.

Também existe justificativa ética. Em educação, sistemas preditivos não devem substituir o julgamento pedagógico humano, mas sim apoiar a priorização e a leitura do contexto. Por isso, o sistema proposto foi concebido como ferramenta de apoio à decisão e não como mecanismo automático de julgamento. Em outras palavras, o objetivo não é rotular o aluno de forma definitiva, mas oferecer sinais adicionais para que a escola consiga agir antes.

1.3 Delimitação do tema

Este trabalho não trata de evasão escolar em sentido amplo, nem pretende substituir os processos formais de avaliação da escola. O foco está na previsão da próxima nota e na identificação de risco pedagógico de curto prazo, com base em registros escolares representados por dados falsos gerados. A pesquisa também se limita ao contrato público desses dados e às rotinas de preparação e extração que sustentam a pipeline publicada. Isso significa que as conclusões do trabalho devem ser lidas dentro desse contexto específico de dados, regras e disponibilidade institucional.

1.4 Estrutura do trabalho

Esta monografia foi organizada em seis capítulos. O Capítulo 1 apresenta o problema, os objetivos e a justificativa. O Capítulo 2 discute a fundamentação teórica e os trabalhos relacionados. O Capítulo 3 descreve a natureza da pesquisa e a evolução histórica do projeto. O Capítulo 4 detalha a arquitetura proposta, a integração dos dados e a construção do dataset. O Capítulo 5 apresenta a modelagem, os relatórios e os resultados experimentais. Por fim, o Capítulo 6 discute limitações, conclusões e trabalhos futuros.

Fundamentação Teórica e Trabalhos Relacionados

Este capítulo apresenta os principais conceitos que sustentam o desenvolvimento deste trabalho. Como a proposta envolve o uso de dados escolares para prever desempenho acadêmico e apoiar decisões pedagógicas, a fundamentação foi organizada em torno da Mineração de Dados Educacionais, do Learning Analytics, da previsão de desempenho escolar, da modelagem temporal, da validação dos modelos e dos cuidados éticos no uso de dados educacionais.

Também são discutidos trabalhos relacionados que ajudam a situar a proposta desta monografia em um campo de pesquisa já consolidado, mas ainda em expansão, especialmente quando se considera o uso prático desses modelos no cotidiano das instituições de ensino.

2.1 Mineração de Dados Educacionais e Learning Analytics

A Mineração de Dados Educacionais (EDM) dedica-se ao desenvolvimento de métodos para explorar dados oriundos de contextos educacionais com o objetivo de compreender, monitorar e melhorar processos de aprendizagem (Romero; Ventura, 2010; Romero *et al.*, 2010). De forma complementar, Learning Analytics (LA) enfatiza a medição, coleta, análise e relato de dados sobre aprendizes e seus contextos para apoiar decisões pedagógicas e institucionais (Siemens; Baker, 2012; Baker; Inventado, 2014).

Neste trabalho, essas duas perspectivas aparecem de forma integrada. Do lado de EDM, o projeto constrói atributos, testa modelos supervisionados e compara métricas. Do lado de LA, o foco está em transformar resultados analíticos em saídas compreensíveis para a rotina escolar. Essa combinação é importante porque o

problema estudado não termina na previsão em si: ele só faz sentido quando a saída pode ser lida e usada por quem toma decisões na escola.

2.2 Previsão de desempenho escolar

Prever desempenho escolar pode assumir diferentes formas: prever evasão, reprovação, engajamento, necessidade de reforço ou nota futura. Este trabalho escolhe como foco principal a previsão da próxima nota, porque esse alvo preserva maior granularidade pedagógica e permite intervenções mais precoces. Em paralelo, o projeto treina um classificador próprio para estimar o risco de a próxima nota ficar abaixo de 6,0, aproximando a modelagem do uso institucional sem reduzir o alerta a uma regra simples aplicada sobre a nota prevista.

2.3 Modelos de aprendizado de máquina no projeto

O projeto avaliou modelos supervisionados adequados a dados tabulares, com histórico irregular entre alunos, disciplinas e anos letivos. A escolha dos candidatos levou em conta quatro critérios práticos: capacidade de capturar relações não lineares, robustez diante de atributos heterogêneos, custo razoável de treinamento e possibilidade de comparar o desempenho com regras simples de referência. Assim, a discussão sobre modelos neste capítulo não tem apenas caráter conceitual: ela ajuda a explicar por que certos caminhos foram testados, descartados ou mantidos na versão final do projeto.

Algoritmos como regressão linear e árvore de decisão simples seriam mais fáceis de explicar, mas tenderiam a representar de forma limitada interações entre nota anterior, tendência, faltas, pagamentos e contexto escolar. Métodos como Support Vector Machine (SVM) poderiam ser usados, mas costumam exigir maior cuidado com escala, ajuste de hiperparâmetros e interpretação em bases tabulares maiores. Redes neurais profundas, por sua vez, foram consideradas menos aderentes ao volume e à irregularidade das sequências disponíveis. Modelos como CatBoost e LightGBM permanecem como alternativas futuras, mas não foram priorizados na versão final para manter a solução mais simples, reproduzível e apoiada em bibliotecas já consolidadas no ambiente do projeto. Em outras palavras, a seleção dos candidatos buscou equilibrar desempenho, legibilidade e viabilidade real de manutenção.

2.3.1 Random Forest

O Random Forest, proposto por Breiman (Breiman, 2001), foi importante no projeto por servir como primeiro modelo tabular forte após a fase exploratória. Sua principal vantagem está na robustez em dados tabulares, na capacidade de capturar relações não lineares e na boa tolerância a atributos heterogêneos. No desenvolvimento deste trabalho, ele teve um papel de referência concreta: ajudou a estabelecer um patamar forte de comparação antes da consolidação de outros candidatos.

2.3.2 LSTM

As redes Long Short-Term Memory (LSTM), introduzidas por Hochreiter e Schmidhuber (Hochreiter; Schmidhuber, 1997), foram consideradas por causa da natureza temporal do problema. No entanto, o conjunto de dados falsos gerados adotado na versão pública preservou sequências irregulares, entradas e saídas de alunos e históricos de extensão muito desigual para manter a complexidade estrutural do problema. Esses fatores reduziram a aderência dessa abordagem ao escopo institucional do trabalho. O ponto aqui não é afirmar que LSTM seja inadequada em termos absolutos, mas reconhecer que, neste conjunto de dados e neste problema, ela não parecia ser a escolha mais consistente.

2.3.3 Gradient Boosting

O Gradient Boosting, formalizado por Friedman (Friedman, 2001), mostrou-se especialmente adequado à solução final por trabalhar bem com dados tabulares e atributos derivados. A variação HistGradientBoosting foi incluída por ser eficiente em bases tabulares e por lidar bem com padrões não lineares. Na rodada final, ele foi o melhor candidato para o modo de alerta de risco, enquanto o Random Forest permaneceu competitivo e foi selecionado para a regressão no modo de previsão de nota. Esse resultado reforça que o projeto não convergiu para um único modelo universal, mas para escolhas diferentes conforme a natureza de cada tarefa.

2.3.4 Classificação supervisionada e regras simples

Uma decisão importante foi manter a classificação de risco como tarefa supervisionada, em vez de utilizar apenas regras fixas, como “se a nota prevista for menor que 6, então o aluno está em risco”. Essa regra seria simples, mas perderia parte do comportamento temporal do problema. O aluno pode ter uma nota prevista numericamente próxima da média e, ainda assim, apresentar padrão de queda,

histórico anterior fraco na disciplina, faltas acumuladas ou distância negativa em relação à turma. A classificação aprende diretamente com exemplos históricos quais combinações desses sinais antecederam notas futuras abaixo de 6,0. Essa escolha ajuda a aproximar o alerta da dinâmica real do acompanhamento escolar.

Isso não elimina as regras. No projeto, regras e pontuações continuam sendo usadas na camada de relatórios e priorização. A diferença é que o alerta principal de risco é estimado por um classificador treinado sobre dados falsos gerados compatíveis com o contrato público, enquanto as regras ajudam a organizar a comunicação pedagógica e a calibrar prioridades.

2.4 Dados temporais, validade e métricas

Um ponto crítico em aplicações educacionais é a validação temporal. Em vez de dividir aleatoriamente treino e teste, este trabalho adota separação por anos letivos, evitando vazamento entre passado e futuro. Essa decisão aproxima a avaliação do uso real da solução, em que a escola precisa prever o próximo período a partir do passado já conhecido. A preocupação com validação temporal também é discutida em estudos sobre avaliação de modelos em dados dependentes do tempo, nos quais uma divisão aleatória pode produzir estimativas otimistas de desempenho (Bergmeir; Hyndman; Koo, 2018). Para este TCC, esse cuidado é central porque o objetivo não era apenas obter uma métrica melhor, mas testar uma situação mais parecida com o uso futuro da pipeline.

As métricas escolhidas acompanham essa dupla natureza do problema. Para regressão, o trabalho utiliza Mean Absolute Error (MAE), que mede o erro médio absoluto em pontos de nota, e Root Mean Squared Error (RMSE), que penaliza erros maiores com mais intensidade. Para classificação de risco, utiliza precision, recall e F1-score (F1). A precision indica, entre os alunos sinalizados, quantos realmente estavam em risco; o recall indica, entre os alunos que realmente estavam em risco, quantos foram recuperados pelo modelo; e o F1 combina essas duas medidas. Essa combinação permite avaliar tanto proximidade numérica quanto capacidade de recuperar casos críticos.

2.5 Ética, privacidade e interpretabilidade

O uso de dados educacionais exige atenção especial à privacidade, à finalidade do tratamento e à interpretação cuidadosa das saídas. Discussões em LA e EDM mostram que proteção de dados e governança não são barreiras para análise, mas condições para seu uso institucionalmente legítimo (Slade; Prinsloo, 2013; Ga-

sevic; Dawson; Jovanovic, 2016; Khalil; Ebner, 2016). No contexto brasileiro, a Lei Geral de Proteção de Dados Pessoais (LGPD) reforça esse cuidado (Brasil, 2018). No caso deste projeto, essa discussão não aparece apenas como requisito formal: ela interfere diretamente na forma de extrair, preparar, armazenar e comunicar os resultados.

Por isso, a versão publicada do projeto passou a trabalhar com dados falsos gerados e assumiu, desde o início, que a saída do sistema não poderia ser um veredito definitivo sobre o aluno. Os relatórios foram desenhados para indicar fatores de alerta e recomendações iniciais, preservando o papel humano na decisão pedagógica (Fiok *et al.*, 2022).

2.6 Trabalhos relacionados

Os trabalhos relacionados ao tema podem ser agrupados em três eixos. O primeiro reúne revisões gerais da área, como as de Romero e Ventura (Romero; Ventura, 2010) e de Baker e Inventado (Baker; Inventado, 2014). O segundo eixo envolve estudos preditivos aplicados à educação, sobretudo aqueles que combinam múltiplas fontes de informação. O terceiro eixo aborda interpretabilidade, governança e questões éticas. Entre esses conjuntos, os trabalhos mais diretamente ligados a esta monografia são os que tratam de previsão de nota e detecção de risco acadêmico.

2.6.1 Comparação com estudos de previsão de nota e detecção de risco

Considerando o foco deste trabalho em prever a próxima nota e sinalizar risco pedagógico, a literatura mais próxima pode ser organizada em dois subconjuntos: estudos voltados à previsão de nota futura e estudos voltados à detecção de alunos em risco acadêmico. No primeiro grupo, Morsy e Karypis (Morsy; Karypis, 2017) e Widjaja *et al.* (Widjaja *et al.*, 2020) ajudam a situar o problema da regressão da próxima nota dentro de uma linha de pesquisa já consolidada, embora majoritariamente concentrada em ensino superior.

No segundo grupo, Lakkaraju *et al.* (Lakkaraju *et al.*, 2015) e Koprinska, Stretton e Yacef (Koprinska; Stretton; Yacef, 2015) representam estudos de detecção de risco. Nesse eixo, a proximidade com esta pesquisa aparece menos no tipo exato de alvo e mais na preocupação com identificação precoce, interpretabilidade e utilidade institucional. As Tabelas 1 e 2 sintetizam esses dois recortes comparativos.

Tabela 1 – *Trabalhos correlatos focados em previsão de nota futura.*

Trabalho	Entradas	Saída e métodos	Limite frente a este TCC
Morsy e Karypis (2017)	Histórico aluno-disciplina e relações de conhecimento entre cursos em base universitária	Regressão da nota em disciplinas do próximo período por meio de <i>Cumulative Knowledge-based Regression Models</i>	Foco em matrícula universitária futura; não trata alerta pedagógico por etapa nem relatórios operacionais escolares
Widjaja et al. (2020)	Histórico aluno-curso, atributos de aluno e atributos de curso em contexto universitário	Predição de nota do próximo termo com <i>Factorization Machine</i> e LSTM-FM	Foco em desempenho por termo e escolha de cursos; não integra risco pedagógico separado nem sinais administrativos escolares

Fonte: Elaborada pelo autor com base nos trabalhos citados..

Tabela 2 – *Trabalhos correlatos focados em detecção de risco acadêmico.*

Trabalho	Entradas	Saída e métodos	Limite frente a este TCC
Lakkaraju et al. (2015)	Histórico escolar, notas, ausências, indicadores demográficos e administrativos em dois distritos dos EUA	Classificação binária de risco de não concluir o ensino médio no tempo esperado, com comparação entre classificadores e visualização para gestores	O alvo é conclusão escolar de longo prazo; não prevê a próxima nota da disciplina nem trabalha com saída combinada de regressão e risco
Koprinska, Stretton e Yacef (2015)	Notas parciais, submissões em sistema de correção automática e atividade em fórum de discussão em disciplina de programação	Classificação de aprovação ou falha no exame final com árvore de decisão e regras acionáveis para remediação	Estudo concentrado em uma disciplina universitária e em dados de ambiente digital; não integra contexto financeiro, professor, série ou relatórios multiatores

Fonte: Elaborada pelo autor com base nos trabalhos citados..

Esses estudos mostram que a previsão de nota futura já está consolidada como problema relevante, sobretudo em ensino superior. Entretanto, o alvo adotado costuma ser a nota em disciplinas ainda não cursadas ou em um próximo termo acadêmico. Aqui, a saída de regressão foi reposicionada para a próxima nota observada dentro da sequência temporal da mesma disciplina, o que favorece intervenções pedagógicas de curto prazo no cotidiano escolar. Essa mudança de foco é pequena em aparência, mas importante em termos de uso prático.

Nos estudos de risco, nota-se forte preocupação com identificação precoce, interpretabilidade e apoio à intervenção. Esse ponto aproxima-se diretamente deste TCC. A diferença principal está no fato de que o problema aqui não trata risco apenas como evasão, conclusão tardia ou aprovação final em uma disciplina. O alvo binário foi definido como o risco de a próxima nota observada ficar abaixo de 6,0, o que torna o alerta mais próximo da linguagem pedagógica da escola e mais aderente a decisões de curto prazo.

Do ponto de vista metodológico, o trabalho combina ideias que na literatura frequentemente aparecem separadas. Dos estudos de previsão de nota, aproveita a lógica de usar o histórico acadêmico como base para regressão temporal. Dos estudos de risco, incorpora a necessidade de triagem antecipada, priorização de casos e utilidade institucional. A diferença é que essas duas perspectivas foram unificadas em uma mesma arquitetura temporal com duas saídas supervisionadas: `target_nota_proxima` e `target_risco_proxima`.

Também há diferenças importantes nas entradas e nas ferramentas analíticas. Enquanto os trabalhos universitários de previsão de nota concentram-se sobretudo em relações aluno-curso e atributos acadêmicos, e os trabalhos de risco costumam enfatizar desempenho, engajamento ou indicadores administrativos amplos, este TCC articula notas, faltas, pagamentos, professor e contexto escolar em uma mesma base temporal. Em termos de modelagem, utiliza Random Forest, HistGradientBoosting e baselines heurísticos como referência honesta de comparação, todos avaliados por validação temporal por ano letivo. Em termos de saída, a solução não termina na métrica: as predições alimentam relatórios para professor, coordenação e secretaria, além de ranking executivo de prioridade.

Em relação a esses trabalhos, este TCC se diferencia por articular toda a trajetória de um projeto aplicado: tratamento do banco, refatoração arquitetural, validação temporal, geração de relatórios e ranking executivo. Em vez de comparar apenas algoritmos em um dataset pronto, o trabalho documenta a construção completa de uma solução voltada ao contexto escolar, reunindo previsão da próxima nota, alerta de risco pedagógico e operacionalização institucional em uma mesma pipeline reproduzível. Esse posicionamento ajuda a explicar a contribuição do

trabalho não apenas como experimento de modelagem, mas como solução analítica aplicada.

Materiais, Métodos e Evolução do Projeto

3.1 Natureza da pesquisa

Esta pesquisa é aplicada, predominantemente quantitativa e com forte componente tecnológico-experimental. É aplicada porque busca responder a um problema concreto de acompanhamento escolar. É quantitativa porque trabalha com dados históricos estruturados, métricas preditivas e validação temporal. Também possui componente tecnológico porque não se limita à análise conceitual: envolve a construção efetiva de software, rotinas de extração, pipeline de modelagem e relatórios operacionais.

3.2 Fonte de dados e preparo inicial

Os dados utilizados na versão publicada do projeto são dados escolares falsos gerados para representar registros de alunos, notas, faltas, pagamentos e informações acadêmicas e administrativas sem expor pessoas reais. Esse conjunto foi estruturado para preservar o contrato público da pipeline e a natureza temporal do problema, incluindo diferenças de histórico entre alunos e anos letivos. Como a avaliação temporal depende de conhecer a próxima nota observada, os experimentos finais utilizaram 2025 como ano de teste consolidado; dados de 2026 permanecem relevantes para continuidade operacional, mas nem sempre possuem alvo futuro completo para avaliação experimental. Essa decisão ilustra um ponto importante do trabalho: nem todo dado disponível na base publicada pode ser usado da mesma forma em uma avaliação preditiva honesta.

Os arquivos principais extraídos para a pipeline foram:

- `aluno.csv`;
- `media_nota_aluno.csv`;

- `faltas_aluno.csv`;
- `pagamento_aluno.csv`;
- `responsaveis_aluno.csv`;
- `professor_disciplina.csv`, quando o vínculo docente estava disponível.

A descrição consolidada do contrato dessas entradas, da execução experimental e dos artefatos gerados pela pipeline é apresentada na Seção 4.3.

3.3 Estratégia metodológica

O trabalho foi conduzido de forma incremental. Em vez de partir diretamente para uma solução final, o projeto foi sendo refinado em ciclos de exploração, teste, diagnóstico de limitações e refatoração. Esse percurso não foi um desvio do objetivo do TCC; ao contrário, foi justamente o processo que permitiu identificar quais escolhas se sustentavam diante do problema real e quais pareciam boas apenas em um plano inicial mais abstrato.

Para organizar a apresentação desse percurso, também foi adotada uma leitura inspirada no ciclo *Cross-Industry Standard Process for Data Mining* (CRISP-DM) (Wirth; Hipp, 2000). Assim, o projeto pode ser compreendido em seis movimentos: entendimento do problema escolar, entendimento dos dados, preparação da base, modelagem, avaliação e disponibilização dos resultados em relatórios e painel. Essa estrutura foi usada como material demonstrativo nos notebooks do repositório, sem substituir a arquitetura de produção da aplicação. Em outras palavras, o CRISP-DM foi adotado aqui mais como lente de organização do percurso do que como descrição literal da implementação final.

3.4 Evolução histórica do projeto

3.4.1 Fase inicial orientada a grafo

O projeto começou com uma hipótese baseada em grafos heterogêneos, motivada pela natureza relacional do domínio escolar. Nessa etapa, foram produzidos módulos para leitura de entidades, construção de relações e consultas em estruturas relacionais. A ideia era representar alunos, matrículas, disciplinas, responsáveis, faltas e pagamentos como nós e arestas. Essa fase foi importante porque ajudou a explicitar a riqueza relacional do domínio, mesmo que depois ela não tenha permanecido como base da solução final.

3.4.2 Fase exploratória com testes clássicos e PCA

Na sequência, o projeto incorporou análises estatísticas e testes com classificadores tradicionais, além de redução exploratória de dimensionalidade com *Principal Component Analysis* (PCA). Essa fase foi importante para entender a distribuição dos atributos e perceber que o problema exigia mais do que uma base estática pivotada. Também foi nesse momento que ficou mais claro que o desempenho do aluno não poderia ser tratado de forma satisfatória sem considerar a ordem temporal das observações.

3.4.3 Fase temporal com LSTM

Como o problema possui natureza temporal, foi investigada também uma abordagem sequencial com *Long Short-Term Memory* (LSTM). Apesar de conceitualmente promissora, essa alternativa não se consolidou, sobretudo por depender de sequências mais homogêneas e longas do que as observadas na base. Na prática, a irregularidade dos históricos e a variedade de trajetórias entre alunos reduziram a aderência dessa solução ao escopo institucional do trabalho.

3.4.4 Fase tabular com Random Forest

Posteriormente, o projeto migrou para um desenho mais pragmático com Random Forest. Essa fase representou um avanço importante por aproximar a solução de um problema tabular supervisionado. Ainda assim, permaneceram limitações relacionadas ao pivotamento excessivo, perda de temporalidade e uso incompleto de dados como faltas e pagamentos. Foi uma etapa decisiva porque mostrou que o projeto estava mais próximo de uma formulação tabular temporal do que de uma representação fixa centrada apenas em atributos agregados.

3.4.5 Refatoração para pipeline real

O amadurecimento do trabalho levou primeiro à consolidação de uma pipeline intermediária de experimentação, e depois à arquitetura final entregue no pacote `school_predictor`. Essa arquitetura separou explicitamente:

- a camada de acesso e conexão com o banco;
- a preparação local dos insumos e a geração de dados falsos compatíveis com o contrato público;
- a extração dos dados para arquivos canônicos;
- a pipeline de modelagem e relatórios;
- a camada de visualização em dashboard.

Na versão final do repositório, a aplicação pública foi organizada em torno de `school_predictor/`, enquanto detalhes locais de preparação de insumos permaneceram fora do Git. Essa decisão tornou a solução mais adequada à publicação acadêmica, concentrando a reprodução no contrato dos arquivos e no uso de dados falsos gerados. Mais do que uma escolha de organização de código, isso foi parte do esforço para tornar o trabalho reproduzível sem depender de dados institucionais sensíveis.

3.5 Critérios de avaliação

Os critérios de avaliação foram definidos em duas camadas. A primeira camada é estatística e envolve MAE, RMSE, precision, recall e F1. A segunda camada é institucional e pergunta se a solução consegue priorizar casos urgentes, gerar relatórios compreensíveis e apoiar diferentes atores escolares. Essa combinação foi necessária porque um modelo matematicamente competente nem sempre é automaticamente útil para a escola. Em um projeto como este, desempenho preditivo e utilidade operacional precisaram ser lidos em conjunto desde o início.

Arquitetura da Solução e Integração dos Dados


Este capítulo apresenta a arquitetura final da solução e a forma como os dados escolares foram integrados para viabilizar a previsão da próxima nota e a identificação de risco pedagógico. A organização aqui descrita não surgiu pronta desde o início; ela foi sendo consolidada à medida que o projeto deixou de ser apenas um conjunto de experimentos e passou a exigir uma estrutura reproduzível, compreensível e segura para publicação acadêmica.

4.1 Visão geral da arquitetura

O fluxo consolidado pode ser resumido em oito etapas:

1. preparação local dos insumos e geração de dados falsos compatíveis com o contrato público;
2. extração das tabelas relevantes para arquivos *Comma-Separated Values* (CSV);
3. leitura estruturada dessas fontes pela pipeline;
4. construção do dataset longitudinal;
5. separação temporal entre treino, validação e teste;
6. comparação automática entre modelos e baselines;
7. geração de previsões e análises de erro;
8. produção de relatórios operacionais para a escola.

Em termos de organização do código, o núcleo da solução ficou distribuído entre módulos de configuração, leitura das entradas, construção do dataset, modelagem, geração de artefatos e relatórios. A Figura 1 sintetiza essa organização em camadas maiores, priorizando a leitura do caminho dos dados e das responsabilidades principais da solução.

Figura 1 – *Visão arquitetural da solução proposta.*

Fonte: Elaborada pelo autor.

4.2 Modos de execução

A aplicação foi organizada para funcionar em dois cenários complementares. No cenário completo, a rotina parte da preparação local dos insumos, segue para a extração dos CSVs canônicos e termina na execução da pipeline com geração de relatórios. No cenário público reproduzível, o ponto de partida são os CSVs já estruturados a partir de dados falsos gerados, a partir dos quais os modos analíticos e a recomposição da camada final podem ser executados sem acesso a dados institucionais.

Esse desenho permite separar o que depende de infraestrutura local controlada do que pode ser demonstrado, documentado e reproduzido academicamente. A Figura 2 representa o fluxo operacional principal, desde a preparação e extração até a execução dos modos de modelagem e a geração dos relatórios finais.

Figura 2 – *Fluxo operacional principal da solução.*

Fonte: Elaborada pelo autor.

4.3 Configuração experimental e reprodutibilidade

4.3.1 Camadas de entrada

A reprodução da solução foi separada em duas camadas complementares:

- camada privada local: prepara insumos locais, quando necessário, e concentra detalhes operacionais que não fazem parte da versão pública;
- camada pública reproduzível: consome os CSVs canônicos em `artifacts/database/csv/` e executa a pipeline acadêmica publicada no repositório.

Essa separação foi adotada para que a parte sensível da extração permanecesse protegida, enquanto a parte acadêmica e demonstrativa da solução continuasse passível de reprodução por terceiros.

4.3.2 Arquivos de entrada canônicos

Os arquivos de entrada da arquitetura final foram definidos da seguinte forma:

- `aluno.csv`: identifica o aluno por registros artificiais consistentes com o contrato público e preserva o contexto cadastral e escolar básico da extração;
- `media_nota_aluno.csv`: base principal de notas por aluno, disciplina, período e etapa; é o eixo central da modelagem;
- `faltas_aluno.csv`: registros de faltas usados para formar faltas por etapa e faltas acumuladas;
- `pagamento_aluno.csv`: registros financeiros resumidos para produzir sinais administrativos por aluno e ano letivo;
- `responsaveis_aluno.csv`: arquivo canônico complementar do projeto, preservado como parte do contrato público da extração;
- `professor_disciplina.csv`: contexto docente por disciplina e turma, incorporado quando esse vínculo está disponível.

Na pipeline central publicada, os arquivos consumidos diretamente pela modelagem e pelos relatórios são, principalmente, `media_nota_aluno.csv`, `faltas_aluno.csv`, `pagamento_aluno.csv` e `professor_disciplina.csv`. Os demais arquivos preservam o contrato público da extração e a rastreabilidade da arquitetura completa, mesmo quando não entram diretamente em todas as etapas da modelagem.

4.3.3 Execução reproduzível da pipeline

A execução experimental do projeto pode ser compreendida em dois cenários complementares.

No cenário completo, disponível apenas em ambiente local com acesso controlado aos insumos de preparação, a rotina segue três movimentos:

1. preparar localmente os insumos por meio da rotina `prepare-db`;
2. extrair os arquivos canônicos por meio da rotina `extract`;
3. executar a pipeline completa com a rotina `workflow`, responsável por acionar os dois modos principais e consolidar a camada final de relatórios.

No cenário público reproduzível, basta disponibilizar os CSVs canônicos em `artifacts/database/csv/`. A partir deles, a execução pode ocorrer por modo isolado ou de ponta a ponta:

- `pipeline -mode previsao_nota`: executa apenas o modo voltado à regressão da próxima nota;

- `pipeline -mode alerta_risco`: executa apenas o modo voltado à classificação de risco;
- `reports`: recompõe a camada final de relatórios a partir dos artefatos já produzidos;
- `workflow`: reconstitui o fluxo completo e produz a saída operacional final.

Essa organização foi importante porque o experimento final não depende de acesso direto ao banco para ser reproduzido academicamente; ele depende do contrato dos CSVs e de uma interface de execução padronizada.

4.3.4 Modos e artefatos analíticos

Cada modo da pipeline grava seus resultados em um subdiretório de `artifacts/pipeline/`. Os diretórios centrais são:

- `artifacts/pipeline/previsao_nota/`;
- `artifacts/pipeline/alerta_risco/`.

Em ambos os casos, os principais artefatos gerados são:

- `student_prediction_dataset.csv`: base final preparada para a rodada de modelagem;
- `student_prediction_predictions.csv`: predições e sinais de teste usados na avaliação;
- `student_prediction_report.txt`: resumo técnico com métricas e candidatos selecionados;
- `student_prediction_model.pkl`: modelo final persistido quando a solução vencedora depende de objeto supervisionado treinado;
- `error_analysis_by_subject.csv`: consolidação de erro por disciplina;
- `error_analysis_by_series.csv`: consolidação de erro por série;
- `error_analysis_by_score_band.csv`: consolidação de erro por faixa de nota;
- `error_analysis_summary.txt`: resumo textual das análises de erro.

Esses artefatos sustentam a leitura técnica do experimento, pois registram o tamanho da base resultante, os candidatos comparados, o desempenho temporal, as predições no teste e os pontos de maior dificuldade do sistema.

4.3.5 Artefatos operacionais finais

Após a execução dos dois modos, a camada final de disponibilização grava saídas em `artifacts/reports/`. Entre os arquivos mais relevantes estão:

- `relatorio_escolar_integrado.csv`: base consolidada que cruza previsão de nota, alerta de risco e sinais operacionais;
- `relatorio_professor.csv` e `relatorio_professor.txt`: visão por aluno e disciplina para apoio pedagógico direto;
- `relatorio_coordenacao.csv` e `relatorio_coordenacao.txt`: consolidados por série, disciplina e prioridade institucional;
- `relatorio_secretaria.csv` e `relatorio_secretaria.txt`: sinais administrativos e prioridades de contato;
- `relatorio_professores_por_turma.csv`: consolidação de risco por professor e turma;
- `relatorio_professores_geral.csv`: consolidação geral de risco por professor;
- `ranking_executivo_coordenacao` em formatos `.csv` e `.txt`: priorização executiva dos alunos mais urgentes para intervenção.

Esses relatórios representam a saída final do experimento no contexto do TCC, pois convertem resultados de modelagem em materiais de consulta orientados aos diferentes perfis institucionais da escola.

4.3.6 Condição mínima de reprodutibilidade

Assim, a condição mínima para reproduzir publicamente a configuração experimental não é o acesso ao banco institucional, mas sim a disponibilidade dos CSVs canônicos e a observância do fluxo operacional da aplicação.

4.4 Integração de notas, faltas, pagamentos e professores

O trabalho foi estruturado para unir quatro blocos principais de informação:

- desempenho acadêmico;
- frequência;
- sinais administrativos e financeiros;
- contexto escolar, incluindo disciplina, série, turma e professor.

Do ponto de vista de engenharia, a entrada de dados foi organizada em duas camadas. A primeira camada é privada e local, responsável pela preparação dos insumos e pela geração dos arquivos necessários à versão pública. A segunda camada é pública e reproduzível, baseada nos arquivos CSV canônicos consumidos

pela pipeline em `artifacts/database/csv/`. Isso permite explicar e reproduzir a arquitetura sem depender de dados institucionais identificáveis.

Conforme sintetizado na Seção 4.3, essa separação define o contrato de reprodução da solução. Nesta seção, o foco passa a ser a forma como esses blocos de dados foram integrados na modelagem. As notas representam o eixo central da modelagem. A partir delas, foram construídos históricos deslocados, médias móveis, tendências e estatísticas de referência. As faltas foram agregadas por etapa e acumuladas ao longo do tempo. Os pagamentos foram resumidos por ano letivo, incluindo quantidades, pendências e médias de atraso. O professor, quando disponível no banco atualizado, foi incorporado como atributo contextual, sem remover linhas quando o vínculo docente estivesse ausente.

4.5 Engenharia de atributos

Os atributos criados para a modelagem incluem:

- nota anterior 1, 2 e 3;
- média das últimas notas;
- desvio histórico da disciplina;
- tendência da última nota;
- média histórica do aluno no ano;
- média do aluno no ano anterior;
- média da disciplina no ano anterior;
- média da corte por etapa;
- faltas da etapa;
- faltas acumuladas;
- movimentos financeiros registrados e pendentes no ano;
- dias até pagamento;
- indicador de disponibilidade do professor.

Os atributos diretamente derivados da trajetória de notas e faltas foram construídos por deslocamentos, acumulados ou agregações até a etapa observada, preservando a causalidade temporal do problema. Os sinais financeiros, por sua vez, foram usados como contexto administrativo agregado por aluno e ano letivo. Por isso, devem ser interpretados como variáveis institucionais de apoio, e não como evidência causal isolada do desempenho.

4.6 Construção do alvo e prevenção de vazamento

Foram definidos dois alvos principais:

1. `target_nota_proxima`, correspondente ao valor numérico da próxima nota observada;
2. `target_risco_proxima`, correspondente ao indicador binário de próxima nota inferior a 6,0.

Para evitar vazamento de informação, os atributos históricos de desempenho e frequência foram calculados por deslocamento, médias acumuladas ou agregações limitadas ao passado. Isso foi essencial para garantir que o desempenho medido refletisse um cenário real de uso, e não apenas um ajuste artificial a dados futuros. A prevenção de vazamento, neste caso, não foi um detalhe técnico menor, mas uma condição para que os resultados tivessem valor prático.

4.7 Camada de relatórios

Além da modelagem, a arquitetura incorpora uma camada própria de relatórios. Ela organiza saídas para os principais perfis escolares e consolidados complementares:

- relatório do professor, com foco por aluno e disciplina;
- relatório da coordenação, com agregados por série e disciplina;
- relatório da secretaria, com ênfase administrativa;
- ranking executivo de alunos prioritários;
- relatório escolar integrado, usado como base operacional unificada;
- consolidados de risco por professor, com e sem recorte por turma.

Essa camada foi decisiva para aproximar a solução do problema real da escola, convertendo resultados técnicos em informação acionável. O inventário operacional desses artefatos foi consolidado na Seção 4.3. Essa escolha também ajuda a marcar a diferença entre o que o modelo calcula e o que a escola efetivamente consome.

4.8 Estrutura final do repositório e do fluxo operacional

Na forma final do projeto, a base ativa do software ficou organizada nos seguintes blocos:

- `school_predictor/database`: acesso ao banco, wrappers públicos de preparação e extração, e contrato das consultas;
- `school_predictor/database/private_runtime.py`: camada local privada para preparação física do banco e extração com tratamento sensível;
- `school_predictor/database/private_sql/`: consultas SQL reais mantidas apenas no ambiente local;
- `school_predictor/pipeline`: construção do dataset, modelagem, avaliação e relatórios;
- `school_predictor/app`: dashboard em Streamlit;
- `artifacts/database/csv`: interface canônica de entrada da pipeline;
- `artifacts/pipeline` e `artifacts/reports`: saídas analíticas e operacionais.

Com isso, a arquitetura final passou a separar claramente o que precisa ficar privado por envolver estrutura institucional do banco e o que pode ser publicado para fins acadêmicos, reprodutibilidade e apresentação do TCC. Esse arranjo resume bem a direção adotada pelo projeto: preservar o contexto real da escola sem comprometer a possibilidade de explicar, auditar e continuar a solução.

4.9 Síntese técnica da replicação da solução

Do ponto de vista metodológico, a reprodução desta solução foi organizada com base numa interface pública de dados de entrada, formada pelos ficheiros canônicos conservados em `artifacts/database/csv/`. Esta escolha possibilita distinguir a fase institucional de extração, que requer uma base de dados restaurada e procedimentos privados locais, da fase acadêmica de reprodução, que pode ser executada a partir de ficheiros tabulares já consolidados e definidos semanticamente. Em termos práticos, a extração institucional continua associada à camada privada, enquanto a reprodução acadêmica passa a ter início, de forma adequada, a partir do contrato destes CSVs.

Na estrutura divulgada, os pontos mais imediatos de acesso a esses dados estão na configuração do fluxo de trabalho e na importação das tabelas fundamentais.

Na prática, a configuração da pipeline define os caminhos esperados para os CSVs canônicos da solução. Em seguida, a camada de leitura realiza a importação padronizada dessas fontes e organiza a carga preliminar para fins analíticos. Depois disso, a camada de orquestração incorpora essa carga ao fluxo principal. Já a rotina privada de banco permanece restrita à camada local, responsável pela preparação da base restaurada e pela extração anterior ao processamento geral.

Do ponto de vista da replicabilidade acadêmica, o experimento pode ser refeito caso os arquivos essenciais estejam acessíveis com a precisão necessária. Na essência da análise da solução, quatro conjuntos de dados são fundamentais: `media_nota_aluno.csv`, que detalha as notas dos estudantes por matéria, semestre e fase; `faltas_aluno.csv`, que enriquece o percurso educacional com os dados de frequência; `pagamento_aluno.csv`, que inclui informações financeiras; e `professor_disciplina.csv`, que oferece detalhes sobre os professores quando essa relação é conhecida. Os arquivos `aluno.csv` e `responsaveis_aluno.csv`, ainda que não sejam utilizados em todas as fases da construção do modelo, mantêm a base de dados públicos e reforçam a organização geral da solução.

Com o intuito de simplificar este acordo, as Tabelas 3 a 8 fornecem ilustrações sintéticas, eficazes e pseudônimas de entradas dos repositórios padronizados. Essas representações não suplantam o detalhamento integral das colunas nem a documentação técnica elaborada para o empreendimento. Sua função é demonstrar, visualmente, o esqueleto primordial de uma entrada antes do processamento analítico e facultar a confirmação da existência dos dados indispensáveis à reprodução. Adicionalmente, elas auxiliam na clarificação de como cada entrada conjuga três aspectos constantes da inclusão: o ambiente educacional, a relação do estudante e os detalhes particulares do acontecimento registrado.

Tabela 3 – *aluno.csv*.

IDUnidade	Nome Período	Nome Curso	Nome Série	IDAluno	Nome Aluno
U1	2025	Ensino Médio	1ª Série	A1001	Aluno Exemplo

Tabela 4 – *media_nota_aluno.csv*.

IDAluno	Nome Disciplina	Nome Etapa	Valor Media	Nome Série	IDTurma	Nome Período
A1001	Matemática	1º BIMESTRE	7.5	1ª Série	T1	2025

Tabela 5 – *faltas_aluno.csv*.

IDAluno	Nome Disciplina	Nome Etapa	DataFalta	Nome Série	IDTurma	Nome Período
A1001	Matemática	1º BIMESTRE	2025-03-12	1ª Série	T1	2025

Tabela 6 – *pagamento_aluno.csv*.

IDAluno	Desc. Mov.	Venc. Mov.	Valor Mov.	Pago?	Mensal.?	Período
A1001	Mensal. Mar.	2025-03-05	850.0	Sim	Sim	2025

Tabela 7 – *responsaveis_aluno.csv*.

IDAluno	Nome Aluno	IDResponsavel	Nome Responsavel	Tipo Responsavel
A1001	Aluno Exemplo	R9001	Responsável Exemplo	Mãe

Tabela 8 – *professor_disciplina.csv*.

IDTurma	Nome Serie	Nome Disciplina	IDFuncionario	Nome Funcionario	Nome Período
T1	1ª Série	Matemática	F2001	Professor Exemplo	2025

As tabelas exibem compilações visuais sucintas de entradas e ajudam a validar a existência e a estrutura das informações coletadas. O detalhamento completo das colunas está especificado no corpo do texto e na documentação técnica associada ao projeto. Essa diferenciação é crucial, visto que o processo de pipeline não se limita à leitura de dados individualizados; ele processa conjuntos de registros que exigem consistência entre os períodos, séries, turmas, disciplinas e alunos.

Em termos práticos, o desenvolvimento oficial da solução se inicia com estes documentos, elabora o conjunto de dados temporais para modelagem, aplica os métodos de análise da etapa e salva suas conclusões em `artifacts/pipeline/`. Em seguida, a seção de relatórios junta as saídas finais em `artifacts/reports/`. Desta forma, o trabalho apresenta um registro tecnicamente verificável e academicamente replicável da solução, sem revelar os detalhes institucionais confidenciais utilizados na organização e obtenção dos dados iniciais.

Modelagem, Relatórios e Resultados

5.1 Modelos candidatos e critérios de seleção

A etapa de modelagem comparou candidatos de regressão, candidatos de classificação e baselines determinísticos. Essa organização foi importante porque o objetivo não era apenas treinar um algoritmo sofisticado, mas verificar se ele realmente acrescentava valor em relação a regras simples baseadas no próprio histórico de notas. Em um problema escolar, essa comparação é especialmente relevante: se uma heurística simples entrega resultado próximo ao de um modelo mais custoso, o ganho prático da solução precisa ser analisado com cuidado.

Os candidatos avaliados foram:

- *RandomForestRegressor* e *RandomForestClassifier*;
- *HistGradientBoostingRegressor* e *HistGradientBoostingClassifier*;
- baseline de última nota;
- baseline de média das duas últimas notas;
- baseline de média das três últimas notas;
- baseline híbrido.

Para regressão, o critério principal de seleção foi o Mean Absolute Error (MAE). Para classificação de risco, o critério principal foi o F1-score (F1), acompanhado de *precision* e *recall*. O MAE foi escolhido porque expressa o erro diretamente em pontos de nota, o que facilita a interpretação pedagógica. O F1 foi usado porque equilibra a capacidade de encontrar casos críticos com a precisão dos alertas emitidos.

5.2 Comparação dos candidatos na validação

A Tabela 9 mostra a comparação dos principais candidatos de regressão na etapa de validação. No modo de previsão de nota, o Random Forest foi ligeiramente superior ao HistGradientBoosting em MAE, por isso foi selecionado como regressor

principal desse modo. No modo de alerta de risco, por outro lado, o HistGradientBoosting foi o melhor regressor dentro do recorte com histórico mínimo maior. Mais do que apontar um vencedor absoluto, essa comparação indica que o comportamento dos candidatos muda conforme o recorte operacional da base.

Tabela 9 – *Comparação dos candidatos de regressão na validação.*

Modo e candidato	MAE	RMSE	Erro $\leq 0,5$
Previsão – Random Forest	0,8152	1,0907	0,4261
Previsão – HistGradientBoosting	0,8191	1,0926	0,4156
Previsão – baseline de última nota	0,9148	1,3015	0,4531
Alerta – HistGradientBoosting	0,8124	1,1113	0,4429
Alerta – Random Forest	0,8327	1,1167	0,4174
Alerta – baseline de duas notas	0,9196	1,2746	0,4248

Fonte: Elaborada pelo autor com base nos artefatos da pipeline..

A Tabela 10 apresenta a comparação dos candidatos de classificação para risco. O resultado mostra duas evidências importantes. Primeiro, baselines simples ainda são competitivos e precisam ser considerados. Segundo, no modo especificamente calibrado para alerta de risco, o HistGradientBoostingClassifier superou os demais candidatos em F1. Isso reforça que a classificação não pode ser tratada apenas como derivada automática da regressão; ela possui comportamento próprio e exige calibração específica.

Tabela 10 – *Comparação dos candidatos de classificação na validação.*

Modo e candidato	Precision	Recall	F1
Previsão – baseline de duas notas	0,7011	0,7744	0,7359
Previsão – HistGradientBoosting	0,6172	0,8937	0,7302
Previsão – Random Forest	0,5743	0,9158	0,7059
Alerta – HistGradientBoosting	0,6980	0,8255	0,7564
Alerta – baseline de duas notas	0,7165	0,7908	0,7518
Alerta – Random Forest	0,6091	0,9036	0,7277

Fonte: Elaborada pelo autor com base nos artefatos da pipeline..

5.3 Estabilidade das rodadas experimentais

Além da comparação entre candidatos, a pipeline foi executada em múltiplas rodadas para verificar se os resultados usados na análise permaneciam estáveis. Essa validação foi importante porque o trabalho compara modelos supervisionados com baselines baseados no histórico do aluno, como última nota, média das duas últimas notas, média das três últimas notas e baseline híbrido.

Os modelos foram configurados com semente fixa (`random_state = 42`) e execução controlada. Dessa forma, a expectativa era que uma nova execução com os mesmos CSVs de entrada preservasse métricas, candidatos selecionados e predições. A validação de estabilidade verifica exatamente esse ponto: se a repetição da pipeline altera MAE, RMSE, F1, *recall*, candidatos escolhidos ou a classificação de risco de algum aluno.

Na rodada final de verificação, os modos `previsao_nota` e `alerta_risco` foram executados cinco vezes cada um. No modo de previsão de nota, as execuções preservaram o *RandomForestRegressor* como regressor selecionado e o baseline de média das duas últimas notas como classificador de referência. No modo de alerta de risco, as cinco execuções preservaram o *HistGradientBoostingRegressor* e o *HistGradientBoostingClassifier*. Em ambos os modos, não houve alteração nas métricas, nos candidatos selecionados nem nas predições geradas. Os resumos dessa verificação foram registrados nos artefatos `run_stability_summary.txt` e `run_stability_comparison.csv` de cada modo da pipeline.

Essa etapa não substitui validação externa em outra escola ou em outro período letivo. Seu papel é mais restrito: confirmar que os resultados relatados não dependem de uma execução isolada acidental e que a comparação com as médias históricas do aluno permanece reproduzível no ambiente atual.

5.4 Resultados do modo de previsão de nota

No modo `previsao_nota`, o melhor cenário foi obtido com histórico mínimo igual a 1. A base de modelagem alcançou 106.721 linhas, 1.378 alunos únicos, 53 disciplinas e 6 anos letivos considerados. O conjunto temporal foi organizado com treino em anos anteriores, validação em 2024 e teste em 2025. Esse recorte confirma um aspecto importante da arquitetura: para prever a próxima nota, vale a pena preservar mais observações, mesmo quando o histórico individual ainda é relativamente curto.

O melhor candidato de regressão foi o *RandomForestRegressor*, com os resultados finais apresentados na Tabela 11. Em termos práticos, a previsão da

próxima nota ficou, em média, a aproximadamente 0,77 ponto da nota realmente observada, superando a heurística simples de repetir a nota anterior. Esse ganho indica que o modelo capturou padrões adicionais da trajetória escolar, sem depender apenas da medição mais recente.

Ao mesmo tempo, a métrica de acerto com erro $\leq 0,5$ permaneceu abaixo de 50%, o que delimita o alcance da solução. A previsão não deve ser entendida como substituta da avaliação docente nem como mecanismo automático de fechamento de nota. Seu papel é reduzir incerteza e oferecer um sinal antecipado sobre trajetória de melhora, estabilidade ou queda, apoiando a triagem pedagógica com maior cobertura de alunos e disciplinas.

Tabela 11 – *Resultados finais do modo de previsão de nota no teste temporal.*

Métrica	Valor
MAE do modelo	0,7659
RMSE do modelo	1,0519
Acerto com erro $\leq 0,5$	0,4649
MAE do baseline de última nota	0,9138
RMSE do baseline de última nota	1,2967

Fonte: Elaborada pelo autor com base nos artefatos da pipeline..

5.5 Resultados do modo de alerta de risco

No modo `alerta_risco`, o melhor cenário foi obtido com histórico mínimo igual a 2. Nessa configuração, a base de modelagem alcançou 50.065 linhas, 1.179 alunos únicos e 53 disciplinas. O melhor classificador foi o HistGradientBoostingClassifier, com os resultados apresentados na Tabela 12. Em comparação com o modo de previsão de nota, a base fica menor, mas o sinal histórico torna-se mais consistente para uma tarefa de alerta.

O destaque está no *recall*. Em um sistema de alerta, perder casos realmente críticos tende a ser mais grave do que sinalizar alguns casos adicionais para acompanhamento. Por isso, esse resultado foi considerado adequado ao objetivo pedagógico do trabalho: priorizar alunos que merecem revisão humana, não produzir uma decisão automática.

Esse comportamento também diferencia os dois modos da pipeline. Enquanto a regressão busca aproximação numérica da nota futura, a classificação de

risco privilegia cobertura dos casos potencialmente problemáticos. O fato de o melhor desempenho ocorrer com `min_history = 2` sugere que o alerta depende mais de padrões temporais acumulados, como recorrência de queda, instabilidade ou permanência em faixas de desempenho sensíveis.

Tabela 12 – *Resultados finais do modo de alerta de risco no teste temporal.*

Métrica	Valor
Precision do modelo	0,6442
Recall do modelo	0,8794
F1 do modelo	0,7436
F1 do baseline	0,7243

Fonte: Elaborada pelo autor com base nos artefatos da pipeline..

A Tabela 13 resume a matriz de confusão do modo de alerta de risco no teste temporal. Dos 2.794 casos que realmente tiveram próxima nota abaixo de 6,0, o modelo recuperou 2.457. Por outro lado, também sinalizou 1.357 casos que não se confirmaram como risco no alvo observado. Para uma ferramenta de triagem, esse comportamento é aceitável: um falso positivo representa acompanhamento preventivo adicional, enquanto um falso negativo pode significar a perda de uma oportunidade de intervenção antes do fechamento da etapa.

Tabela 13 – *Matriz de confusão do alerta de risco no teste temporal.*

Risco real	Predito sem risco	Predito com risco
Sem risco	9.092	1.357
Com risco	337	2.457

Fonte: Elaborada pelo autor com base nos artefatos da pipeline..

5.6 Comparando históricos mínimos

Os testes de histórico mínimo mostraram um resultado relevante para a arquitetura do projeto:

- `min_history = 1` foi melhor para regressão da próxima nota, pois preservou mais alunos e disciplinas na base;

- `min_history = 2` foi melhor para classificação de risco, pois exigiu maior evidência histórica antes de sinalizar alerta;
- `min_history = 3` reduziu demais a quantidade de casos e inviabilizou a validação temporal na rodada analisada.

Essa evidência levou à separação da pipeline em dois modos complementares de uso, cada um com sua configuração mais adequada. Trata-se de uma conclusão importante do TCC, porque mostra que a diferença entre prever nota e sinalizar risco não é apenas de métrica final, mas também de quantidade mínima de evidência histórica aceitável.

5.7 Exemplo interpretado de alerta

A Tabela 14 apresenta um caso demonstrativo retirado dos artefatos de teste com dados falsos gerados. O exemplo é útil porque mostra por que o projeto manteve um classificador de risco, e não apenas uma regra baseada na nota prevista.

Tabela 14 – *Caso demonstrativo sinalizado pelo alerta de risco.*

Campo	Valor observado
Aluno, série e disciplina	Aluno 01790, 1ª Série, Biologia 2
Etapa analisada	3º bimestre de 2025
Nota atual e próxima nota real	6,3 na etapa atual; 5,8 na etapa seguinte
Notas anteriores na disciplina	5,5 e 4,5
Média das duas últimas notas	5,0
Faltas acumuladas	7 faltas até a etapa analisada
Pagamentos pendentes no ano	0 pendências registradas
Média da corte na etapa	6,98
Professor vinculado	Professor 00019
Nota prevista pelo regressor	6,58
Alerta do classificador	Risco sinalizado corretamente

Fonte: Elaborada pelo autor com base nos artefatos da pipeline..

Se o sistema usasse apenas a regra “nota prevista menor que 6”, esse caso não seria sinalizado, pois a previsão numérica foi 6,58. O classificador, entretanto, identificou o risco a partir do conjunto de sinais: histórico anterior fraco na disciplina,

média recente abaixo da linha de segurança, faltas acumuladas e desempenho abaixo da média da corte. Esse exemplo mostra que a regressão e a classificação são complementares. Ele também ajuda a explicar por que o trabalho optou por manter duas saídas supervisionadas em vez de reduzir todo o problema a uma única previsão numérica.

5.8 Geração de relatórios escolares

Os resultados preditivos não foram o ponto final da solução. A partir deles, a camada final de relatórios passou a organizar saídas para três perfis institucionais:

- professor: com nota atual, nota prevista, fatores de alerta e recomendação pedagógica;
- coordenação: com visão por série, disciplina, ranking executivo e consolidados por professor;
- secretaria: com sinais administrativos relacionados a frequência, financeiro e prioridade de contato.

Essa operacionalização aparece nos artefatos gerados pela pipeline. Entre eles estão o relatório do professor, o da coordenação, o da secretaria, os consolidados por professor e o ranking executivo. Cada arquivo reorganiza o mesmo núcleo analítico para uma pergunta institucional diferente: o professor acompanha casos por disciplina, a coordenação observa concentrações por série, turma e docente, e a secretaria visualiza sinais administrativos de frequência, financeiro e prioridade de contato.

Além dos relatórios tabulares, foi estruturado um painel visual em Streamlit para leitura gerencial dos artefatos. O painel organiza visão geral, painel do professor e painel da coordenação, permitindo filtrar períodos, séries e disciplinas e inspecionar distribuições de risco, rankings e relações entre nota atual e nota prevista. Com isso, a etapa de resultados passa a incluir não apenas o desempenho dos modelos, mas também a forma como suas saídas podem ser consultadas no cotidiano escolar.

5.9 Análise de erro e calibração

A análise de erro mostrou maior dificuldade de previsão em disciplinas como Matemática 3, Matemática 4 e 5, Biologia 2, História 2 e Química 3. Também houve maior erro nas faixas de nota abaixo de 7, especialmente porque esses casos são mais instáveis e pedagogicamente sensíveis. Essa concentração sugere que parte do erro está associada a trajetórias com maior oscilação, possivelmente influenciadas

por lacunas de pré-requisitos, mudanças de rotina, recuperação parcial, faltas ou diferenças de exigência entre etapas.

Na camada operacional, a primeira regra de risco gerava excesso de casos classificados como alto risco. Por isso, foi criada uma pontuação composta que passou a combinar:

- predição de risco do modelo;
- nota prevista;
- nota atual;
- variação esperada;
- faltas acumuladas;
- pendências financeiras.

Tabela 15 – *Principais pontos de erro no modo de alerta de risco.*

Grupo analisado	Amostras	MAE	Acurácia de risco
Matemática 4 e 5	81	1,9489	0,7778
Biologia 2	260	1,5895	0,6500
História 2	81	1,3741	0,6667
Faixa abaixo de 6	2.794	1,0395	0,8794
Faixa de 6 a 6,99	1.405	0,9718	0,5103

Fonte: Elaborada pelo autor com base nos artefatos da pipeline..

Com essa calibração, a priorização ficou mais compatível com o uso institucional, reduzindo sobrecarga sobre coordenação e professores. Em síntese, os experimentos sustentam a decisão arquitetural adotada na versão atual do projeto: dois modos supervisionados complementares, validação temporal e entrega final em relatórios orientados por papel institucional.

Discussão, Limitações e Conclusão

Este capítulo retoma os principais resultados do trabalho, explicita suas limitações, sintetiza a contribuição alcançada e apresenta possibilidades de continuidade. O objetivo é fechar a narrativa do TCC de forma coerente com a evolução do projeto e com o uso institucional pretendido para a solução.

6.1 Discussão dos resultados

Os resultados mostram que a solução final apresentou aderência melhor ao problema do que as hipóteses iniciais do projeto. Embora grafos e LSTM tenham sido importantes na fase exploratória, a experiência empírica indicou que o problema central estava melhor representado por uma base tabular temporal com atributos derivados e validação cronológica. Essa conclusão é relevante porque não foi assumida de antemão: ela surgiu do confronto entre diferentes caminhos metodológicos e os limites concretos da base escolar analisada.

Outro ponto importante é o valor dos baselines. Em diferentes momentos do trabalho, regras simples baseadas na última nota ou em médias móveis competiram de forma relevante com modelos mais sofisticados. Isso reforça que complexidade algorítmica não deve ser tomada como sinônimo automático de superioridade. No contexto deste TCC, esse cuidado ajudou a manter a análise mais honesta e mais próxima do uso real da solução.

Do ponto de vista institucional, o maior avanço do projeto não está apenas nas métricas, mas na passagem da predição para a ação. O valor do sistema aparece quando a nota prevista, o alerta de risco e os sinais complementares são convertidos em relatórios inteligíveis para professor, coordenação e secretaria. Na prática, esses alertas devem orientar investigação pedagógica, priorização de contato, planejamento de reforço e acompanhamento da evolução do aluno. Em outras palavras, a contribuição do trabalho se sustenta mais quando a modelagem é lida como apoio à decisão do que como mecanismo autônomo de julgamento.

6.2 Limitações do trabalho

As principais limitações identificadas foram:

1. o vínculo de professor ainda não cobre integralmente todo o histórico analisado;
2. o ranking executivo ainda concentra muitos casos nas faixas mais altas de prioridade;
3. a base de 2026 já existe, mas nem todos os cenários possuem alvo consolidado suficiente para teste completo;
4. o projeto utiliza variáveis institucionais disponíveis, mas não incorpora dimensões qualitativas, socioemocionais ou contextuais mais profundas;
5. a generalização para outras escolas exige adaptação local da arquitetura e nova validação.

Também existem ameaças à validade interna, externa e de construção. Nem toda queda de desempenho é explicada pelas variáveis disponíveis, e conceitos educacionais complexos acabam representados por *proxies* quantitativos, como faltas, pagamentos e trajetória de notas. Essa limitação não invalida o projeto, mas delimita com mais clareza o alcance de suas interpretações.

6.3 Conclusão

Este Trabalho de Conclusão de Curso apresentou o desenvolvimento de um sistema preditivo para apoio à decisão pedagógica demonstrado com dados escolares falsos gerados. O projeto evoluiu de uma hipótese inicial orientada a grafos para uma pipeline temporal tabular reproduzível, capaz de:

- prever a próxima nota do aluno com desempenho superior a baselines simples;
- identificar risco de nota futura abaixo de 6 com *recall* elevado;
- integrar notas, faltas, pagamentos e contexto escolar em uma arquitetura única;
- transformar resultados técnicos em relatórios operacionais para diferentes atores da escola.

Em termos quantitativos, o modo de previsão numérica atingiu MAE de 0,7659, enquanto o modo de alerta de risco alcançou F1 de 0,7436 e *recall* de 0,8794 no teste temporal. Em termos práticos, esses resultados indicam que a solução já pode servir como mecanismo de triagem e priorização institucional, desde que usada com supervisão humana e interpretação contextualizada. O ponto central não é afirmar que a escola passa a “saber o futuro” do aluno, mas que passa a dispor de um instrumento adicional para agir com mais antecedência.

Assim, a principal contribuição do trabalho não está apenas em acertar melhor uma nota futura, mas em mostrar que é possível construir uma arquitetura analítica coerente com o cotidiano da escola, eticamente defensável e operacionalmente útil. Nesse sentido, o TCC procura contribuir menos com uma promessa de solução definitiva e mais com uma forma consistente de integrar dados, modelagem e uso institucional em educação.

6.4 Trabalhos futuros

Como continuidade natural do projeto, o principal desdobramento previsto é consolidar o sistema como uma plataforma de relatórios operacionais para colégios e faculdades. A proposta é evoluir os artefatos demonstrados neste TCC para um fluxo recorrente de acompanhamento, no qual a modelagem alimente relatórios voltados a decisões pedagógicas e administrativas.

Nesse cenário, coordenadores, professores e secretaria passariam a consultar relatórios específicos para identificar alunos com maior risco de queda, disciplinas com concentração de alertas, turmas que exigem intervenção coletiva e casos que demandam contato administrativo. O objetivo é antecipar medidas de apoio antes que o problema se consolide como reprovação bimestral, trimestral, semestral ou anual.

Para isso, os relatórios atuais devem evoluir de saídas analíticas do TCC para um mecanismo institucional mais estável, com ciclos de atualização definidos, filtros por unidade, curso, turma e disciplina, e trilhas de acompanhamento que permitam verificar se o caso melhorou após a intervenção. Em faculdades, a mesma arquitetura pode ser adaptada a componentes curriculares semestrais, disciplinas com alta reprovação histórica, sinais de evasão e combinações entre desempenho acadêmico e informações administrativas.

Outra ampliação relevante será obter dados acadêmicos mais detalhados sobre tarefas e atividades realizadas pelos alunos. Além das notas formais, faltas e pagamentos, futuras versões podem incorporar informações sobre tarefas propostas, tarefas realizadas, entregas no prazo, entregas atrasadas, atividades não entregues e notas ou conceitos atribuídos a essas atividades. O cruzamento desses sinais com as médias escolares e com o histórico de desempenho pode revelar indícios mais precoces de queda, dificuldade de organização, desengajamento ou lacunas de aprendizagem, fortalecendo a capacidade do sistema de antecipar risco acadêmico antes da reprovação.

Também será necessário aprofundar a escolha do algoritmo mais adequado quando o sistema for testado em diferentes colégios e faculdades. Embora este

trabalho tenha consolidado uma pipeline tabular reproduzível, a decisão final entre modelos como *Random Forest* e *HistGradientBoosting* deve considerar o comportamento observado em bases institucionais distintas, com diferentes volumes de dados, padrões de avaliação, distribuição de faltas, organização de turmas e históricos de reprovação. Essa comparação deve manter o mesmo cuidado adotado neste TCC: validação temporal, comparação com baselines simples e análise do custo pedagógico dos erros.

Por fim, a evolução para uso operacional exigirá ajustes no sistema RP da instituição, especialmente na definição de regras, telas e notificações que transformem o risco previsto em ação concreta. Um exemplo previsto é a criação de alertas no aplicativo móvel do professor, permitindo que ele seja avisado quando um aluno apresentar risco acadêmico relevante e possa consultar os principais sinais associados ao alerta. Esse recurso deve ser implementado com cuidado para evitar excesso de notificações, preservar a interpretação pedagógica e manter a decisão final sob responsabilidade humana.

Além disso, permanecem relevantes os seguintes desdobramentos técnicos:

1. ampliar a cobertura do vínculo com professores e reduzir casos sem identificação docente;
2. recalibrar os limiares do ranking executivo e da pontuação composta para diminuir sobrecarga operacional;
3. incorporar técnicas adicionais de explicabilidade para justificar melhor cada alerta;
4. medir o impacto real dos relatórios nas decisões de coordenadores, professores e secretaria;
5. comparar *Random Forest* e *HistGradientBoosting* em bases de diferentes instituições para definir qual modelo se ajusta melhor ao uso pretendido;
6. incorporar dados de tarefas, entregas, atrasos, não entregas e notas de atividades, cruzando esses sinais com as médias escolares e com o histórico de desempenho do aluno;
7. integrar os alertas ao sistema RP e ao aplicativo móvel do professor, com regras de notificação, consulta dos motivos do alerta e controle de sobrecarga operacional;
8. validar a solução em outras escolas, cursos superiores ou redes educacionais.

Referências

BAKER, Ryan S. J. d.; INVENTADO, Paulo S. Educational data mining and learning analytics. *In*: LARUSSON, Johann Ari; WHITE, Brandon (Ed.). **Learning Analytics: From Research to Practice**. New York: Springer, 2014. p. 61–75. 10, 14

BERGMEIR, Christoph; HYNDMAN, Rob J.; KOO, Bonsoo. A note on the validity of cross-validation for evaluating autoregressive time series prediction. **Computational Statistics & Data Analysis**, v. 120, p. 70–83, 2018. 13

Brasil. **Lei nº 13.709, de 14 de agosto de 2018**. 2018. Lei Geral de Proteção de Dados Pessoais. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 21 abr. 2026. 14

BREIMAN, Leo. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. 12

FIOK, Krzysztof; KARWOWSKI, Waldemar; GUTIERREZ, Eduardo; WILAMOWSKI, Bogdan; REZA, Ali; AHRAM, Tareq. Explainable artificial intelligence for education and training. **Human Factors in Emerging Technologies and Society**, v. 19, n. 2, 2022. 14

FRIEDMAN, Jerome H. Greedy function approximation: A gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001. 12

GASEVIC, Dragan; DAWSON, Shane; JOVANOVIĆ, Jelena. Ethics and privacy as enablers of learning analytics. **Journal of Learning Analytics**, v. 3, n. 1, p. 1–4, 2016. 13, 14

HOCHREITER, Sepp; SCHMIDHUBER, Jürgen. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. 12

KHALIL, Mohammad; EBNER, Martin. De-identification in learning analytics. **Journal of Learning Analytics**, v. 3, n. 1, p. 129–138, 2016. 13, 14

KOPRINSKA, Irena; STRETTON, Joshua; YACEF, Kalina. Students at risk: Detection and remediation. *In: Proceedings of the 8th International Conference on Educational Data Mining*. International Educational Data Mining Society, 2015. p. 512–515. Disponível em: <https://www.educationaldatamining.org/EDM2015/proceedings/short512-515.pdf>. Acesso em: 1 jun. 2026. 14

LAKKARAJU, Himabindu; AGUIAR, Everaldo; SHAN, Carl; MILLER, David; BHANPURI, Nasir; GHANI, Rayid; ADDISON, Kecia L. A machine learning framework to identify students at risk of adverse academic outcomes. *In: Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: ACM, 2015. p. 1909–1918. 14

MORSY, Sara; KARYPIS, George. Cumulative knowledge-based regression models for next-term grade prediction. *In: Proceedings of the 2017 SIAM International Conference on Data Mining*. Philadelphia: SIAM, 2017. p. 552–560. 14

ROMERO, Cristóbal; VENTURA, Sebastián. Educational data mining: A review of the state of the art. *IEEE Transactions on Systems, Man, and Cybernetics, Part C*, v. 40, n. 6, p. 601–618, 2010. 10, 14

ROMERO, Cristóbal; VENTURA, Sebastián; PECHENIZKIY, Mykola; BAKER, Ryan S. J. d. (Ed.). *Handbook of Educational Data Mining*. Boca Raton: CRC Press, 2010. 10

SIEMENS, George; BAKER, Ryan S. J. d. Learning analytics and educational data mining: Towards communication and collaboration. *In: Proceedings of the 2nd International Conference on Learning Analytics and Knowledge*. New York: ACM, 2012. p. 252–254. 10

SLADE, Sharon; PRINSLOO, Paul. Learning analytics: Ethical issues and dilemmas. *American Behavioral Scientist*, v. 57, n. 10, p. 1510–1529, 2013. 13, 14

WIDJAJA, Audrey Tedja; WANG, Lei; TRUONG, Nghia Trong; GUNAWAN, Aldy; LIM, Ee-Peng. Next-term grade prediction: A machine learning approach. *In: Proceedings of the 13th International Conference on Educational Data Mining*. International Educational Data Mining Society, 2020. p. 700–703. Disponível em: https://educationaldatamining.org/files/conferences/EDM2020/papers/paper_97.pdf. Acesso em: 1 jun. 2026. 14

WIRTH, Rüdiger; HIPPE, Jochen. *CRISP-DM: Towards a Standard Process Model for Data Mining*. Manchester: [s.n.], 2000. 19

Apêndice A – Estrutura resumida da solução

Este apêndice resume os principais blocos do repositório utilizados pela versão final do TCC.

A.1 Organização do repositório

- `school_predictor`: base ativa da aplicação final;
- `artifacts`: entrada e saída canônicas da pipeline no ambiente local;
- `docs`: documentação textual do projeto e apoio à defesa;
- `monografia`: projeto LaTeX da monografia e do pré-projeto;
- `diagrama`: diagramas da arquitetura e do fluxo de modelagem.

A.2 Módulos centrais da pipeline

`school_predictor/database/access.py` define a conexão com o banco por variáveis de ambiente;

`school_predictor/database/maintenance.py` expõe o wrapper público da preparação do banco;

`school_predictor/database/extraction.py` expõe o wrapper público da extração;

`school_predictor/database/private_runtime.py` concentra localmente as etapas privadas de preparação e extração;

`school_predictor/pipeline/dataset.py` constrói o dataset longitudinal e a engenharia de atributos;

`school_predictor/pipeline/modeling.py` realiza a validação temporal, seleção de candidatos e avaliação;

`school_predictor/pipeline/reporting.py` produz os relatórios para professor, coordenação e secretaria;

`school_predictor/cli.py` orquestra a operação principal do projeto.

A.3 Artefatos principais gerados

Entre os principais artefatos produzidos pela pipeline estão:

- arquivos CSV canônicos em `artifacts/database/csv`;
- artefatos analíticos por modo em `artifacts/pipeline/previsao_nota/` e `artifacts/pipeline/alerta_risco/`, incluindo dataset final, previsões, relatório técnico e análises de erro;
- relatórios operacionais em `artifacts/reports/`, com saídas para professor, coordenação e secretaria;
- relatório escolar integrado, consolidados por professor e ranking executivo da coordenação;
- painel em Streamlit para visualização operacional.

O detalhamento conceitual dessas entradas, saídas e artefatos está concentrado na Seção 4.3, enquanto este apêndice apenas resume a estrutura final da solução.