



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS

PRÓ-REITORIA DE ENSINO

CÂMPUS GOIÂNIA

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

WARLEY RODRIGUES DE ANDRADE

Redes Neurais para Grafos como ferramentas para reconhecimento de padrões em dados educacionais

Pré-Projeto de Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Sistemas de Informação como requisito parcial para obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Otávio Calaça Xavier

Goiânia, 2023.

1 INTRODUÇÃO

Nos últimos anos, as redes neurais de grafos tornaram-se uma importante área de pesquisa em computação e ciência de dados, ganhando destaque tanto na academia quanto na indústria (Kipf; Welling, 2017). Esta abordagem destaca-se por sua capacidade de processar grandes quantidades de dados interligados, fornecer *insights* valiosos e identificar padrões complexos em sistemas também complexos. Suas aplicações foram encontradas em uma ampla gama de disciplinas, incluindo análise de dados educacionais, em que o reconhecimento de padrões desempenha papel relevante na identificação de tendências e na melhoria da experiência acadêmica (Wang; Wang, 2021).

O reconhecimento de padrões nos dados educacionais é fundamental, pois pode contribuir para prevenir a evasão escolar e melhorar o progresso acadêmico dos alunos. No entanto, as limitações de métodos tradicionais de reconhecimento de padrões frequentemente dificultam a detecção precoce de problemas e a implementação de intervenções eficazes (Jain; Murty, 2020). Nesse contexto, as redes neurais de grafos surgem como uma ferramenta promissora para melhorar o reconhecimento de padrões em dados educacionais.

Sua capacidade de modelar relações complexas entre diferentes variáveis e entidades pode fornecer métodos de reconhecimento mais precisos e eficazes, permitindo a detecção precoce de problemas acadêmicos e a aplicação de intervenções mais direcionadas.

2 JUSTIFICATIVA

O principal argumento deste pré-projeto é que as redes neurais de grafos têm potencial para melhorar significativamente a precisão e a eficiência do reconhecimento de padrões educacionais, favorecendo intervenções precoces e estratégias mais eficazes de acompanhamento. O trabalho pretende explorar de forma detalhada como redes neurais de grafos podem ser aplicadas à análise de dados educacionais para identificar padrões no desempenho dos alunos e fatores que influenciam seu progresso acadêmico.

Além disso, o estudo propõe investigar o impacto prático dessa abordagem nas instituições de ensino e discutir estratégias de intervenção baseadas nos *insights*

gerados por redes neurais de grafos.

O texto do Trabalho de Conclusão de Curso (TCC) seria dividido em seções principais, incluindo revisão da literatura sobre redes neurais de grafos e reconhecimento de padrões em dados educacionais, descrição detalhada da metodologia, apresentação dos resultados obtidos com conjuntos de dados reais e discussão das implicações práticas desses resultados. Também se previu a análise de limitações, desafios e direções futuras de pesquisa.

3 OBJETIVOS

O objetivo deste trabalho é investigar e desenvolver um modelo de redes neurais de grafos capaz de melhorar o reconhecimento de padrões em dados educacionais, com foco na identificação precoce de problemas envolvendo alunos em risco de evasão escolar e na identificação de fatores que contribuem para o fracasso acadêmico. Em perspectiva, a proposta visa ajudar instituições escolares a antecipar esses acontecimentos e construir métodos para evitá-los.

As questões de pesquisa que orientam o estudo são:

1. Como as redes neurais para grafos podem ser aplicadas com sucesso à análise de dados educacionais?
2. Em comparação com métodos tradicionais, em que medida essa abordagem melhora a precisão e a eficiência do reconhecimento de padrões?
3. Quais são as implicações práticas da aplicação de redes neurais gráficas em ambientes educacionais?
4. Quais são as limitações e os desafios dessa abordagem e como podem ser superados?

Essas questões orientam a investigação proposta e buscam contribuir para a melhoria da qualidade da educação e para o enfrentamento de desafios institucionais recorrentes.

4 REFERENCIAL TEÓRICO

A evasão escolar e o desempenho acadêmico abaixo do esperado em instituições de ensino prejudicam não apenas o progresso educacional dos alunos, mas também a eficácia dos sistemas de ensino. Além disso, a dificuldade em identificar e

intervir precocemente em problemas acadêmicos limita a capacidade das instituições de proporcionar uma educação de qualidade.

O objetivo deste trabalho é explorar o uso de redes neurais de grafos na análise de dados educacionais como uma abordagem inovadora para enfrentar o problema da evasão escolar e melhorar o desempenho dos estudantes. As redes neurais de grafos emergiram como uma alternativa promissora devido à sua capacidade de modelar relações complexas entre entidades interconectadas.

4.1 Redes Neurais de Grafos

As redes neurais de grafos são uma extensão das redes neurais convencionais voltada à modelagem de dados interconectados. Essa abordagem representa os dados como um grafo em que os nós representam entidades e as arestas capturam as relações entre elas. Dessa forma, essas redes conseguem aprender representações ricas e hierárquicas dos dados.

Casalegno (Casalegno, 2021) destaca que grafos são estruturas altamente versáteis para aprendizado de máquina, mas que seu tratamento não é trivial por envolver dados não estruturados e não euclidianos. Nesse cenário, as redes convolucionais de grafos (Graph Convolutional Networks (GCN)) ampliam o conceito das redes neurais convolucionais para dados estruturados em forma de grafo, permitindo tarefas como classificação de grafos, classificação de nós e previsão de ligações.

4.2 Análise de Dados Educacionais

A análise de dados educacionais envolve a coleta e o processamento de informações relacionadas ao desempenho acadêmico dos alunos, interações em sala de aula e outros fatores relevantes. Seu objetivo é fornecer *insights* que possam melhorar a qualidade do ensino, identificar padrões de desempenho e prever evasão escolar.

Dekker, Pechenizkiy e Vleeshouwers (Dekker; Pechenizkiy; Vleeshouwers, 2009) demonstraram, em investigação de mineração de dados educacionais, que classificadores relativamente simples e de fácil interpretação, como árvores de decisão, podem produzir resultados valiosos para antecipar evasão de estudantes, alcançando precisão entre 75% e 80%.

4.3 Redes Neurais de Grafos na Educação

O uso de redes neurais de grafos na análise de dados educacionais ganhou destaque por sua capacidade de lidar com a complexidade inerente aos sistemas educacionais. Essas redes podem capturar relacionamentos multifacetados entre alunos, cursos, professores e outras entidades envolvidas no processo educacional. Pesquisas anteriores apontam aplicações como:

1. detecção de padrões de comportamento do aluno;
2. previsão de abandono escolar;
3. recomendação de cursos e recursos;
4. avaliação de eficácia do ensino.

4.4 Comparando com métodos tradicionais

Embora os métodos tradicionais de análise de dados educacionais sejam amplamente utilizados, eles geralmente apresentam limitações na captura de relações complexas. Bhatti et al. (Bhatti *et al.*, 2023) apontam que redes neurais de grafos, adaptadas para dados não euclidianos, têm sido amplamente usadas em diversas áreas justamente por sua capacidade de lidar com estruturas em grafo. Essa vantagem reforça o interesse em investigar sua aplicação em cenários educacionais.

Essa revisão estabelece a base do estudo proposto e sustenta a investigação sobre como redes neurais de grafos poderiam ser empregadas para melhorar a compreensão de padrões acadêmicos e prevenir a evasão escolar.

5 METODOLOGIA DE PESQUISA

A abordagem de pesquisa proposta neste pré-projeto envolve um conjunto de etapas planejadas para investigar como redes neurais de grafos podem ser aplicadas ao reconhecimento de padrões em dados educacionais.

5.1 Coleta de dados

1. Seleção de fontes de dados educacionais, como registros acadêmicos, informações de desempenho, dados demográficos e outras variáveis relevantes.
2. Obtenção de permissão de acesso aos dados, com atenção às questões de privacidade e ética.

5.2 Pré-processamento

1. Limpeza de dados para remoção de valores faltantes, inconsistências e *outliers*.
2. Transformação dos dados conforme necessário, incluindo padronização, codificação de variáveis categóricas e demais ajustes pertinentes.

5.3 Modelagem com redes neurais de grafos

1. Seleção da arquitetura apropriada para a natureza dos dados, como Graph Convolutional Network (GCN) ou Graph Neural Network (GNN).
2. Treinamento do modelo com ajuste de hiperparâmetros e monitoramento por métricas adequadas.
3. Validação cruzada para avaliar a capacidade de generalização para novos dados.

5.4 Desenvolvimento do modelo

1. Definição do objetivo do modelo como previsão de desempenho e identificação de problemas acadêmicos.
2. Seleção de variáveis de entrada relevantes, como notas, desempenho acadêmico, dados demográficos e outras variáveis.
3. Escolha da arquitetura de rede neural convolucional de grafo.
4. Treinamento e avaliação do modelo nos dados educacionais.

5.5 Análise dos resultados

1. Avaliação do desempenho em termos de precisão, sensibilidade, especificidade e demais métricas adequadas.
2. Interpretação dos padrões identificados pelo modelo para extrair *insights* educacionais significativos.

5.6 Limitações e desafios

O estudo prevê a identificação e discussão de limitações, como possíveis distorções nos dados, questões de interpretabilidade do modelo e restrições éticas.

5.7 Conclusões e recomendações futuras

Ao final, o trabalho deverá sintetizar os principais resultados e contribuições e indicar caminhos para pesquisas futuras que ampliem ou aprimorem a aplicação de redes neurais de grafos a dados educacionais.

6 CRONOGRAMA

O cronograma do pré-projeto original previa a distribuição das atividades ao longo do ano, contemplando preparação, coleta de dados, análise, escrita e defesa. A Tabela 1 reproduz essa organização de forma mais fiel ao documento original.

Tabela 1 – *Cronograma do pré-projeto.*

Atividade	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov
Fase 1: Preparação		2 sem									
* Revisão da literatura		1 sem									
* Formulação das questões de pesquisa			1 sem								
Fase 2: Coleta de Dados			2 sem								
* Seleção e aquisição dos dados			1 sem								
* Pré-processamento dos dados				4 sem							
Fase 3: Análise de Dados					4 sem						
* Treinamento da Rede Neural para Grafos						2 sem					
* Aplicação da rede aos dados educacionais						2 sem					
* Avaliação de resultados								2 sem			
Fase 4: Escrita do TCC								4 sem			
* Estruturação da tese									1 sem		
* Redação da introdução e revisão									1 sem		
* Desenvolvimento dos capítulos										2 sem	
* Revisão e formatação										1 sem	
Fase 5: Defesa do TCC										1 sem	
* Preparação para a defesa oral											1 sem
Fase 6: Entrega Final											1 sem
* Revisão final e correções											1 sem
* Entrega da versão final do TCC											1 sem

Fonte: Adaptada do cronograma presente no PDF do pré-projeto..

Referências

BHATTI, Uzair Aslam; TANG, Hao; WU, Guilu; MARJAN, Shah; HUSSAIN, Aamir. Deep learning with graph convolutional networks: An overview and latest applications in computational intelligence. **International Journal of Intelligent Systems**, 2023. 5

CASALEGNO, F. **Graph Convolutional Networks: Deep Learning on Graphs**. [S.l.]: Springer Nature, 2021. 4

DEKKER, G. W.; PECHENIZKIY, M.; VLEESHOUWERS, J. M. **Predicting Students Drop Out: A Case Study**. [S.l.]: Springer Nature, 2009. 4

JAIN, A. K.; MURTY, M. N. **Deep Learning for Education: Applications and Challenges**. [S.l.]: Springer Nature, 2020. 2

KIPF, Thomas N.; WELING, Max. **Graph Neural Networks: A Review of Methods and Applications**. 2017. ArXiv preprint arXiv:1703.06876. 2

WANG, Yu Zheng Xin; WANG, Yanyan. Graph neural networks for educational data analysis. **ACM Transactions on Knowledge Discovery from Data**, v. 15, n. 5, 2021. 2